

Atlas ictiogeográfico de la Patagonia occidental: homologación y consolidación de bases de datos

Cristian Correa^{1*} and Maryse Boisjoly¹

¹Instituto de Conservación Biodiversidad y Territorio, Universidad Austral de Chile, Valdivia, Chile.

*Corresponding author(s). E-mail(s): cristiancorrea@gmail.com;

Abstract

Por encargo del Programa Austral Patagonia (ProAP) de The Pew Charitable Trusts, se presenta una recopilación de información detallada de ocurrencia de peces de agua dulce, estuarinos y diadromos en la Patagonia occidental (40.8-56.0°S). Aquí se documenta en detalle la recopilación, análisis, y combinación de 12 conjuntos de datos de ocurrencias, obtenidos empíricamente (a través de prospecciones ictiológicas), a partir de revisiones de literatura, y de distintas bases de datos. El resultado es una base de datos geográfica de ocurrencia de peces en formato compatible con el Darwin Core standard. Hemos llamado al set de datos resultante Atlas Ictiogeográfico de la Patagonia Occidental.

Keywords: peces de agua dulce / freshwater fish, datos de ocurrencia / occurrence data, biomonitorio / biomonitoring, GBIF, Darwin Core, Patagonia occidental / Western Patagonia, Ecology, Conservation biology

Tabla de Contenidos

1	Introduction	4
2	Estrategia metodológica	4
3	Estándar Darwin Core (DwC)	5
4	Listado taxonómico de peces	7
5	Área de estudio y polígonos	9
6	Conjuntos de datos analizados	9
6.1	Datos empíricos de los autores	9
6.1.1	Lectura de datos	10
6.1.2	Filtrado y agregación de datos	11
6.1.3	Filtrado área de estudio	12
6.1.4	Homologación al formato DwC	13
6.1.5	Respaldo	13
6.2	Revisión de literatura C. Correa	14
6.2.1	Lectura de datos	14
6.2.2	Filtrado área de estudio	15
6.2.3	Homologación al DwC	15
6.2.4	Corrección de errores	17
6.2.5	Respaldo	18
6.3	Revisión de literatura M. Aguilar	18
6.3.1	Lectura de datos	18
6.3.2	Homologación al DwC	18
6.3.3	Filtrado área de estudio	19
6.3.4	Respaldo	20
6.4	Base de datos Ministerio del Medio Ambiente de Chile	20
6.4.1	Lectura de datos	21
6.4.2	Comparación de versiones	21
6.4.3	Homologación al DwC	21
6.4.4	Asignación de IDs de la versión GBIF	27
6.4.5	Respaldo	27
6.5	SUBPESCA: Primera base de datos	27
6.5.1	Manejo de referencias	28
6.5.2	Filtrado área de estudio	29
6.5.3	Selección de atributos	30
6.5.4	Estandarización de fechas	31
6.5.5	Estandarización nombre científico	31
6.5.6	Homologación al formato DwC	31

6.5.7	Respaldo	32
6.6	SUBPESCA: Segunda base de datos	32
6.6.1	Lectura de datos homologados	33
6.6.2	Área de estudio	34
6.6.3	Respaldo	34
6.7	Darwin Initiative Fish Atlas	35
6.7.1	Lectura de datos	35
6.7.2	Filtrado y otras correcciones	36
6.7.3	Filtrado área de estudio	36
6.7.4	Homologación al DwC	36
6.7.5	Corrección de errores	37
6.7.6	Respaldo	38

Nota: Esta versión preliminar contiene etiquetas indicando detalles que necesitan atención por parte de los autores. Las etiquetas se identifican con el texto [HERE].

1 Introduction

Los ecosistemas dulceacuícolas tienen un alto grado de amenaza a nivel mundial (Dudgeon et al., 2006). Patagonia occidental no es una excepción, a pesar de la gran cobertura de áreas protegidas. Desde las vulnerables cabeceras de los ríos, y tramos inferiores que están excluidos desde las áreas protegidas, hasta el gran desconocimiento del estado poblacional y distribución de muchas especies dulceacuícolas (Reid, Astorga, Madriz, & Correa, 2021).

En el contexto de un primer esfuerzo regional en avanzar en la planificación de la conservación dulceacuícola en la Patagonia occidental, se desarrolló el informe “Priorización de cuencas para la conservación en Patagonia” (Aguilar, Astorga, & Reid, 2022), donde se identificaron tres ejes de avance: (1) la consolidación de información de biodiversidad de tres grupos taxonómicos dulceacuícolas, (2) la identificación de **subrogantes** geoespaciales que destaquen valores de conservación dulceacuícola, y (3) el desarrollo de un prototipo metodológico para la priorización de múltiples valores de conservación dulceacuícola a la escala de sub-cuenca.

Una de las principales limitantes en esta primera iteración fue la carencia de información sobre biodiversidad dulceacuícola, donde resalta fuertemente el poco conocimiento y la baja densidad de observaciones comparado con otros esfuerzos similares en otras áreas geográficas (Aguilar et al., 2022, p. 26).

Aunque la literatura científica es una fuente importante de información sobre biodiversidad, también hay mucha información de las especies dulceacuícolas en la literatura gris, entidades estatales, bases de dato publicas GBIF y iNaturalist, y, finalmente, en el conocimiento de las/los expertos/as taxónomos y naturalistas. Mucho conocimiento e información que queda en las bases de dato de estos especialistas, que aún no es transcrita a observaciones oficiales, lo cual se relaciona directamente al escaso financiamiento para el trabajo de especialistas. Por lo tanto, una de las recomendaciones principales en este informe y de Reid et al. (2021) fue mejorar la información de biodiversidad integrando al grupo de trabajo a los/as expertas, que con su conocimiento especializado en cada grupo taxonómico lograrían mejorar, consolidar y evaluar las observaciones existentes de biodiversidad. Este atlas ictiográfico es el resultado de este esfuerzo, y también un ejemplo a seguir para otros grupos dulceacuícolas.

El presente documento detalla la metodología en la revisión del material existente, la recopilación, análisis, y combinación de diversos conjuntos de datos de ocurrencias de peces dulceacuícolas y diádomos obtenidos empíricamente (a través de prospecciones ictiológicas), a partir de revisiones de literatura, y de distintas bases de datos. El resultado es una base de datos geográfica de ocurrencia de peces en formato compatible con el Darwin Core standard (DwC), un estándar ampliamente adoptado para la distribución y consolidación de bases de datos biológicas de ocurrencia de especies por entidades tales como el Global Biodiversity Information Facility (GBIF) o la Superintendencia del Medio Ambiente, Gobierno de Chile.

2 Estrategia metodológica

La estrategia metodológica usada para combinar los conjuntos de datos se puede describir a grandes rasgos en cinco partes:

1. Cada set de datos fue visualizado en un mapa y revisado para identificar y corregir inconsistencias y errores.
2. Se homologaron los campos o atributos disponibles (columnas) en cada conjunto de datos con aquellos disponibles en el DwC (ver planilla *Atlas_Ictiogeografico_Homologacion.xlsx*). Básicamente, los nombres de las columnas de cada conjunto de datos fueron reemplazados por los nombres de los mismos atributos del DwC, y en algunos casos se combinaron los campos originales para producir uno homologado.
3. A cada conjunto de datos se le añadieron atributos (columnas) del DwC que son aplicables y propios a cada uno en su totalidad, tal como nombre del conjunto de datos (**datasetName**).
4. Los conjuntos de datos se combinaron en una gran base de datos geográfica reteniendo el mayor número posible de atributos homologados. Esta fue llamada **Atlas Ictiográfico de la Patagonia Occidental** y es el principal producto de este análisis.
5. Dado que hubo considerable redundancia entre conjuntos de datos, el atlas ictiográfico fue examinado de diferentes formas para identificar ocurrencias duplicadas (e.g., mismo registro reportado en dos o más conjuntos de datos). Para esto, se usaron tanto pruebas programáticas tal como la identificación de fechas

y coordenadas repetidas dentro de un rango acotado, como inspección manual de la tabla de atributos a una escala geográfica fina (e.g., sub-cuenca).

En los siguientes capítulos se documenta detalladamente (código R y prosa breve) la adopción del estándar DwC, el proceso de homologación (y otras manipulaciones) de cada conjunto de datos, y el refinamiento y consolidación del atlas ictiogeográfico. Al final, se presenta una breve sección de resultados preliminares examinando el contenido general del Atlas.

Se trabajó en

```
R.version
##
## platform      x86_64-w64-mingw32
## arch          x86_64
## os            mingw32
## crt           ucrt
## system        x86_64, mingw32
## status
## major         4
## minor         4.1
## year          2024
## month         06
## day           14
## svn rev       86737
## language      R
## version.string R version 4.4.1 (2024-06-14 ucrt)
## nickname      Race for Your Life
```

Al final de este documento se presenta la información completa de la sesión de trabajo en R.

3 Estándar Darwin Core (DwC)

“El *Darwin Core* (DwC) (Wieczorek et al., 2012) es un estándar mantenido por el Grupo de Interés de Mantenimiento de Darwin Core (Darwin Core Maintenance Interest Group). Incluye un glosario de términos (en otros contextos podrían llamarse propiedades, elementos, campos, columnas, atributos o conceptos) destinados a facilitar el intercambio de información sobre la diversidad biológica al proporcionar identificadores, etiquetas y definiciones. DwC se basa principalmente en taxa, su presencia en la naturaleza documentada por observaciones, especímenes, muestras e información relacionada.” (traducido de <https://github.com/tdwg/dwc>).

La adopción de un estándar es importante porque fomenta la interoperabilidad entre distintas plataformas y herramientas para el estudio y gestión de la biodiversidad a nivel internacional. El DwC es posiblemente el estándar vigente más ampliamente aceptado internacionalmente para datos de ocurrencia de especies.

La distribución del estándar se hace a través del portal GitHub del Darwin Core Maintenance Interest Group <https://github.com/tdwg/dwc>. Allí se encuentran definiciones, etiquetas, ejemplos, versiones anteriores, entre otros recursos, que a su vez son reflejados en una guía más fácil de leer (Darwin Core Quick Reference Guide).

Una lista de 179 atributos o campos (vigentes y obsoletos) con sus respectivas definiciones, etc., fue obtenida de GitHub (versión 2023-04-28), y de estos una fracción (~36) de los atributos vigentes fue considerado con algún grado de prioridad para los efectos de este proyecto, incluyendo aquellos destacados por la red GBIF como campos primarios y campos obligatorios. La lista completa de atributos y la priorización de esta está disponible en un archivo suplementario (input_parameters/Atlas_Ictiogeografico_Homologacion.xlsx). A continuación se reproduce parte de la lista de atributos seleccionados (Table 1).

Es importante destacar que el campo `eventDate` en el DwC tolera diferentes formatos tales como 2025-11-29 (año), 2025-11 (mes), 2025 (año), e incluso intervalos de tiempo 2023-09-05/2023-09-18 <https://techdocs.gbif.org/en/data-processing/temporal-interpretation>.

```
DwC <- readxl::read_xlsx("input_parameters/Atlas_Ictiogeografico_Homologacion.xlsx",
  sheet = "Matriz de homologacion", skip = 9)
```

Selección de campos que se consideraron prioritarios para este proyecto

```
DwC.keep <- DwC %>%
  filter(!is.na(`Prioridad campo (MB_CC)`))

# table(DwC.keep$`Prioridad campo (MB_CC)`)
```

Table 1: Atributos seleccionados del estándar Darwin Core y su definición. Más detalles y ejemplos de cada uno en archivo excel suplementario.

Darwin Core Terms (DwC)	definition (DwC)
license	A legal document giving official permission to do something with the resource.
rightsHolder	A person or organization owning or managing rights over the resource.
accessRights	Information about who can access the resource or an indication of its security status.
bibliographicCitation	A bibliographic reference for the resource as a statement indicating how this record should be cited (attributed) when used.
references	A related resource that is referenced, cited, or otherwise pointed to by the described resource.
institutionID	An identifier for the institution having custody of the object(s) or information referred to in the record.
collectionID	An identifier for the collection or dataset from which the record was derived.
institutionCode	The name (or acronym) in use by the institution having custody of the object(s) or information referred to in the record.
collectionCode	The name, acronym, coden, or initialism identifying the collection or data set from which the record was derived.
datasetName	The name identifying the data set from which the record was derived.
basisOfRecord	The specific nature of the data record.
occurrenceID	An identifier for the Occurrence (as opposed to a particular digital record of the occurrence). In the absence of a persistent global unique identifier, construct one from a combination of identifiers in the record that will most closely make the occurrenceID globally unique.
catalogNumber	An identifier (preferably unique) for the record within the data set or collection.
recordNumber	An identifier given to the Occurrence at the time it was recorded. Often serves as a link between field notes and an Occurrence record, such as a specimen collector's number.
recordedBy	A list (concatenated and separated) of names of people, groups, or organizations responsible for recording the original Occurrence. The primary collector or observer, especially one who applies a personal identifier (recordNumber), should be listed first.
individualCount	The number of individuals present at the time of the Occurrence.
organismQuantity	A number or enumeration value for the quantity of organisms.
organismQuantityType	The type of quantification system used for the quantity of organisms.
lifeStage	The age class or life stage of the Organism(s) at the time the Occurrence was recorded.
associatedReferences	A list (concatenated and separated) of identifiers (publication, bibliographic reference, global unique identifier, URI) of literature associated with the Occurrence.

otherCatalogNumbers	A list (concatenated and separated) of previous or alternate fully qualified catalog numbers or other human-used identifiers for the same Occurrence, whether in the current or any other data set or collection.
eventDate	The date-time or interval during which an Event occurred. For occurrences, this is the date-time when the event was recorded. Not suitable for a time in a geological context.
year	The four-digit year in which the Event occurred, according to the Common Era Calendar.
verbatimEventDate	The verbatim original representation of the date and time information for an Event.
samplingProtocol	The names of, references to, or descriptions of the methods or protocols used during an Event.
samplingEffort	The amount of effort expended during an Event.
waterBody	The name of the water body in which the Location occurs.
locality	The specific description of the place.
decimalLatitude	The geographic latitude (in decimal degrees, using the spatial reference system given in geodeticDatum) of the geographic center of a Location. Positive values are north of the Equator, negative values are south of it. Legal values lie between -90 and 90, inclusive.
decimalLongitude	The geographic longitude (in decimal degrees, using the spatial reference system given in geodeticDatum) of the geographic center of a Location. Positive values are east of the Greenwich Meridian, negative values are west of it. Legal values lie between -180 and 180, inclusive.
coordinateUncertaintyInMeters	The horizontal distance (in meters) from the given decimalLatitude and decimalLongitude describing the smallest circle containing the whole of the Location. Leave the value empty if the uncertainty is unknown, cannot be estimated, or is not applicable (because there are no coordinates). Zero is not a valid value for this term.
typeStatus	A list (concatenated and separated) of nomenclatural types (type status, typified scientific name, publication) applied to the subject.
scientificName	The full scientific name, with authorship and date information if known. When forming part of an Identification, this should be the name in lowest level taxonomic rank that can be determined. This term should not contain identification qualifications, which should instead be supplied in the IdentificationQualifier term.
kingdom	The full scientific name of the kingdom in which the taxon is classified.
family	The full scientific name of the family in which the taxon is classified.
genus	The full scientific name of the genus in which the taxon is classified.

En el capítulo *Conjuntos de datos analizados* se presenta, uno a la vez, cada conjunto de datos con una breve descripción y la forma en que fue homologado para conformar el estándar DwC.

4 Listado taxonómico de peces

Algunas bases de datos globales requirieron ser filtradas para obtener ocurrencias de peces de interés para este proyecto, y este proceso se hizo basado en criterios geográficos y taxonomicos. Para el criterio taxonómico, este se dividió en dos etapas, una *a priori* y otra *a posteriori*.

En ambos casos se adoptó la clasificación taxonómica de *GBIF Backbone Taxonomy* ([GBIF-Secretariat \(2023\)](#)).

- Filtrado taxonómico *a priori*: Dentro de lo posible, se retuvieron todas las especies de peces (incluso marinas) hasta consolidar la base de datos homologada, y solo entonces se filtró para retener el conjunto de especies de nuestro interés (i.e., Filtrado taxonómico *a posteriori*). Para obtener datos de peces de algunos motores de búsqueda masiva (e.g., GBIF), se hizo una lista completa (inclusiva) de ordenes de

peces, para usarla como criterio de búsqueda. Este paso fue necesario porque la clase Actinopterygii ya no se considera un grupo taxonómico válido en el *GBIF Backbone Taxonomy* porque no es monofilético, lo que significa que no incluye a todos los descendientes de un solo ancestro común (Table 2).

```
res <- name_lookup(rank = "order", higherTaxonKey = 44, isExtinct = F,
  limit = 200)

# res$meta$count # Number of records available
# gbif_names(res) # online result viewer

# Filter fish orders (other taxa display classes in
# 'parent')
fish.orders <- res$data %>%
  filter(parent == "Chordata")
```

Table 2: Ordenes de peces incluidos en la lista de búsqueda a priori.

order	orderKey	taxonomicStatus	habitats
Acipenseriformes	1103	ACCEPTED	FRESHWATER, MARINE
Albuliformes	1104	ACCEPTED	FRESHWATER, MARINE
Amiiformes	494	ACCEPTED	FRESHWATER, MARINE
Anguilliformes	495	ACCEPTED	FRESHWATER, MARINE
Ateleopodiformes	1105	ACCEPTED	MARINE
Atheriniformes	496	ACCEPTED	FRESHWATER, MARINE
Aulopiformes	497	ACCEPTED	MARINE
Batrachoidiformes	1106	ACCEPTED	FRESHWATER, MARINE
Beloniformes	498	ACCEPTED	FRESHWATER, MARINE
Beryciformes	499	ACCEPTED	MARINE
Cetomimiformes	1107	ACCEPTED	MARINE
Characiformes	537	ACCEPTED	FRESHWATER, MARINE
Clupeiformes	538	ACCEPTED	FRESHWATER, MARINE
Cypriniformes	1153	ACCEPTED	FRESHWATER, MARINE
Cyprinodontiformes	547	ACCEPTED	FRESHWATER, MARINE
Elopiformes	1162	ACCEPTED	FRESHWATER, MARINE
Esociformes	548	ACCEPTED	FRESHWATER
Gadiformes	549	ACCEPTED	FRESHWATER, MARINE
Gasterosteiformes	550	ACCEPTED	FRESHWATER, MARINE
Gobiesociformes	1163	ACCEPTED	FRESHWATER, MARINE
Gymnotiformes	1165	ACCEPTED	FRESHWATER
Lampriformes	1166	ACCEPTED	MARINE
Lepisosteiformes	1167	ACCEPTED	FRESHWATER, MARINE
Lophiiformes	1305	ACCEPTED	MARINE
Mugiliformes	1067	ACCEPTED	FRESHWATER, MARINE
Myctophiformes	1306	ACCEPTED	MARINE
Notacanthiformes	1307	ACCEPTED	MARINE
Ophidiiformes	1308	ACCEPTED	FRESHWATER, MARINE
Osmeriformes	1068	ACCEPTED	FRESHWATER, MARINE
Osteoglossiformes	1069	ACCEPTED	FRESHWATER, MARINE
Perciformes	587	ACCEPTED	FRESHWATER, MARINE
Percopsiformes	1310	ACCEPTED	FRESHWATER
Pleuronectiformes	588	ACCEPTED	FRESHWATER, MARINE
Polymixiiformes	589	ACCEPTED	MARINE
Polypteriformes	1311	ACCEPTED	FRESHWATER
Saccopharyngiformes	1312	ACCEPTED	MARINE
Salmoniformes	1313	ACCEPTED	FRESHWATER, MARINE
Scorpaeniformes	590	ACCEPTED	FRESHWATER, MARINE
Siluriformes	708	ACCEPTED	FRESHWATER, MARINE
Stephanoberyciformes	890	ACCEPTED	MARINE
Stomiiformes	774	ACCEPTED	MARINE
Synbranchiformes	889	ACCEPTED	FRESHWATER, MARINE
Syngnathiformes	773	ACCEPTED	FRESHWATER, MARINE
Tetraodontiformes	772	ACCEPTED	FRESHWATER, MARINE
Zeiformes	888	ACCEPTED	FRESHWATER, MARINE

- Filtrado taxonómico *a posteriori*: Una vez homologada y consolidada la base de datos se revisó la lista de taxa resultante y se filtró para retener los taxa de peces de interés para este trabajo. Para esto se preparó una tabla completa de taxa encontrados y se las etiquetó como dulceacuícolas, estuarianas, o diádromas (código 1), y marinas (código 0). Las especies marinas fueron excluidas (ver sección *Consolidación del Atlas Ictiológico, Filtrado taxonómico*).

5 Área de estudio y polígonos

Se definió el área de estudio como el área comprendida por todas las cuencas con vertiente Pacífica que desembocan al sur de la cuenca del Río Maullín. Esto incluye desde Puerto Montt hacia el sur, incluyendo territorio Argentino de cuencas pacíficas, y mares interiores.

Se trabajó con un polígono originalmente proporcionado por Mary Aguilar, y posteriormente simplificado y generalizado a mano para incluir territorio marítimo donde habitan especies diádromas. Además, para mejorar la cobertura del área de estudio en la Patagonia chilena, se agregaron las cuencas chilenas que desembocan hacia el Atlántico. Estas cuencas se encuentran todas en la región de Magallanes. Este polígono fue simplificado nuevamente en QGIS (función *simplify*, with tolerance set to 0.000575) para reducir su número puntos a 9950, y poder ser usado en el motor de búsqueda de GBIF cuyo máximo es 10000 puntos (Study Area Polygon Pacific and Binational.Simp.shp).

```
shapefile_AE_Simp <- st_read("input_parameters/study_area/Study Area Polygon Pacific and Binational.S
  quiet = TRUE)

# Revert the order or orientation of the polygon, and
# convert to WKT for gbif queries.
study.area.wkt_Simp <- st_as_text(st_geometry(st_reverse(shapefile_AE_Simp)))

# Convert to data frame for plotting with ggmap
study.area <- fortify(shapefile_AE_Simp) #>% filter(hole==FALSE)

# Extract coordinates from study.area and keep lat and long
# columns.
study.area.coords <- as.data.frame(st_coordinates(study.area)[,
  1:2])
colnames(study.area.coords) <- c("lon", "lat")

poly <- Polygons(list(Polygon(study.area.coords)), "poly")
sp_poly <- SpatialPolygons(Sr1 = list(poly), proj4string = CRS("EPSG:4326"))

study.area_simp <- fortify(shapefile_AE_Simp) #>% filter(hole==FALSE)
```

El área de estudio resultante se aprecia en la Figura 1.

6 Conjuntos de datos analizados

Se incluyeron 12 conjuntos de datos en el análisis para generar el *Atlas Ictiogeográfico de la Patagonia*. Cada uno fue examinado, corregido en casos de errores, complementado con variables aplicables al nivel del conjunto de datos, y re-formateado para conformar al estándar DwC. Las siguientes secciones documentan el manejo que recibió cada conjunto de datos. Luego, en el capítulo *Consolidación del Atlas Ictiogeográfico*, se combinan todos los conjuntos de datos para conformar una gran tabla maestra que entre otras mejoras, se procesó para identificar ocurrencias duplicadas.

6.1 Datos empíricos de los autores

Nombre corto del conjunto de datos: Fish collection Correa-Boisjoly

Referencia: Correa, Cristián, Maryse Boisjoly (2025) Base de datos empírica de peces de Chile. Valdivia, Chile. (Correa & Boisjoly, 2025)

Archivo: FishDatabase-Correa-Boisjoly_2025-11-27.csv

Este conjunto de datos corresponde a nuestros propios datos empíricos de registros de ocurrencias de peces dulceacuícolas, estuarinos y diádromos en la Patagonia. Algunos de estos registros ya han sido publicados antes pero hay muchos inéditos. Las ocurrencias han sido documentadas en el marco de un número de proyectos de investigación y sus respectivos permisos de pesca de investigación durante los últimos veinte años. En general, el foco de los muestreos ha sido documentar biodiversidad de peces nativos e introducidos,




Fig. 1 Área de estudio.

abarcando un amplio rango de técnicas de muestreo, hábitats y tallas, pero también se hicieron muestreos específicos.

Nuestros datos empíricos se encuentran almacenados en una base de datos relacional en formato MSAccess. A partir de esta, creamos una consulta (Query) incluyendo todas las ocurrencias de peces y un conjunto de atributos o campos relevantes que, como se describe a continuación, fueron homologados al estándar DwC.

6.1.1 Lectura de datos

A partir de la base de datos se exportó una tabla simple (FishDatabase_Correa_Boisjoly_2025-11-27.csv) que se importa y analiza a continuación:

```
FishDB_CC <- read.csv("./data_sources/Correa_Boisjoly_Collection/FishDatabase_Correa_Boisjoly_2025-11-27.csv")
  "character", #Site.name"
  "character", #Locality"
  "character", #Site..waypoint.2014."
  "numeric", #Lat_effort"
  "numeric", #Lon_effort"
  "character", #SiteGear.FieldID"
  "numeric", #Year"
  "character", #Date"
  "character", #Fishing_effort_Id"
  "character", #Technique"
  "numeric", #Fish_Id"
  "character", #Given.ID"
  "character", #YYYY.MM.DD"
  "character", #Species"
  "numeric", #N.Individuals"
  "character", #Preserved."
  "character", #Crew"
  "character", #bibliographicCitation"
  "character" #associatedReferences"
) )
```

```
FishDB_CC$"YYYY.MM.DD" <- as.Date(FishDB_CC$"YYYY.MM.DD", format = "%Y-%m-%d")
```

6.1.2 Filtrado y agregación de datos

En primer lugar, se filtró para retener solamente los peces de este conjunto de datos.

```
FishDB_CC <- FishDB_CC %>%
  filter(!(Species %in% inverts), !is.na(Species))
# where inverts is a vector of names to exclude, mostly
# invertebrates.
```

La tabla de peces resultante presentó 11449 filas o registros y 19 columnas o atributos. Las filas representan ocurrencias de individuos o conjuntos de individuos, por lo que para los efectos de este proyecto es pertinente agregar los datos (combinar filas) para obtener presencia de especies en sitios, fechas y protocolos de muestreos distintos.

Antes de agregar o combinar filas, se corrigieron algunas anomalías con el conteo de individuos para obtener el número de individuos registrado. En particular, cuando el campo `N.Individuals` estaba vacío se asumió `n = 1` porque ese campo sirve sobre todo para acomodar conjuntos de peces indicando su número.

```
# Assume is.na(N.individuals) correspond to n = 1.
FishDB_CC$N.Individuals[is.na(FishDB_CC$N.Individuals)] <- 1

# Lots of still uncounted fish (e.g., photos of fish in
# trays) were originally flagged as N.Individuals = 999,
# and here that value was replaced by NA (all from Valdivia
# though).
FishDB_CC <- FishDB_CC %>%
  mutate(N.Individuals = ifelse((match(N.Individuals, 999,
    nomatch = 0) == 1), NA, N.Individuals))
```

Función para agregar los datos:

```
FishDB_CC_aggregated <- FishDB_CC %>%
  group_by(Locality, Lat_effort, Lon_effort, Year, YYYY.MM.DD,
    Species) %>%
  summarise(Fish_Id = paste0("Correa.Boisjoly.collection.",
    first(Fish_Id)), n = sum(N.Individuals), Technique = paste(unique(Technique),
    collapse = ", "), Site.name = paste(unique(Site.name),
    collapse = ", "), Crew = paste(unique(Crew), collapse = ", "),
    bibliographicCitation = {
      vals <- as.character(bibliographicCitation)
      vals <- trimws(vals)
      vals <- vals[!is.na(vals)]
      vals <- vals[!(vals %in% c("", "NA", "<NA>", "na"))]
      if (length(vals) == 0)
        "" else vals[1]
    }, associatedReferences = {
      vals <- as.character(associatedReferences)
      vals <- vals[!is.na(vals)]
      vals <- trimws(vals)
      vals <- vals[!(vals %in% c("", "NA", "<NA>", "na"))]
      if (length(vals) == 0) {
        ""
      } else {
        parts <- unlist(strsplit(vals, "\\s*\\|\\|\\s*|;\\s*"))
        parts <- trimws(parts)
        parts <- parts[!(parts %in% c("", "NA", "<NA>",
          "na"))]
        parts <- unique(parts)
        if (length(parts) == 0)
```




Fig. 2 Distribución de ocurrencias de peces dulceacuícolas y diádromos según los datos empíricos de los autores de este informe. Datos dentro del polígono del área de estudio en azul.

```

    "" else paste(parts, collapse = " | ")
  }
}, .groups = "drop_last") %>%
ungroup()

```

Hubo muchas ocasiones en las que varios esfuerzos de muestreo practicados en un mismo lugar y fecha se agruparon en una sola fila por especie detectada. En otras palabras, algunas filas representan una ocurrencia obtenida mediante varios protocolos de muestreo. Por tanto, para simplificar, en lo sucesivo hemos optado por omitir identificadores tales como *Effort_Id* y *Fish_Id*.

6.1.3 Filtrado área de estudio

Se aplicó un filtro espacial para extraer las ocurrencias dentro del área de estudio

La versión agregando ocurrencias por fecha, sitio, y especie se redujo de 11449 a 750 filas u ocurrencias (Figura 2).

Los peces reportados por este conjunto de datos dentro del área de estudio se presentan en la Tabla 3.

Table 3: Lista de taxa encontrados en registros empíricos de Fish Database Correa-Boisjoly dentro del área de estudio.

Taxón	Taxón (continuación)
Aplochiton marinus	Odontesthes brevianalis
Aplochiton sp.	Odontesthes hatcheri
Aplochiton taeniatus	Odontesthes regia
Aplochiton zebra	Odontesthes smitti
Brachygalaxias bulloki	Oncorhynchus kisutch
Champsocephalus esox	Oncorhynchus masou
Cheirodon	Oncorhynchus mykiss

Cheirodon interruptus	Oncorhynchus tshawytscha
Cottoberca trigloides	Patagonotothen
Eleginops maclovinus	Patagonotothen sp
Galaxias maculatus	Percichthys trucha
Galaxias maculatus	Salmo salar
Galaxias platei	Salmo trutta
Galaxias sp.	Salvelinus fontinalis
Geotria australis	Sardinops sagax
Geotria macrostoma	Sebastes
Hatcheria macraei	

6.1.4 Homologación al formato DwC

Los campos más importantes fueron homologados como indica la siguiente Tabla 4.

```
FishDB_CC.Fields <- colnames(FishDB_CC_aggregated)

DwC.eq <- FishDB_CC.Fields %>%
  recode(Fish_Id = "occurrenceID", Site.name = "locationRemarks",
    Locality = "locality", Lat_effort = "decimalLatitude",
    Lon_effort = "decimalLongitude", Year = "year", YYYY.MM.DD = "eventDate",
    Species = "scientificName", n = "individualCount", Technique = "samplingProtocol",
    Crew = "recordedBy", bibliographicCitation = "bibliographicCitation",
    associatedReferences = "associatedReferences")

colnames(FishDB_CC_aggregated) <- DwC.eq
FishDB_CC.ready <- FishDB_CC_aggregated[withinAE, ]
```

Table 4: Correspondencia entre atributos para homologar con DwC.

Fish Database Correa-Boisjoly	DwC equivalent
Locality	locality
Lat_effort	decimalLatitude
Lon_effort	decimalLongitude
Year	year
YYYY.MM.DD	eventDate
Species	scientificName
Fish_Id	occurrenceID
n	individualCount
Technique	samplingProtocol
Site.name	locationRemarks
Crew	recordedBy
bibliographicCitation	bibliographicCitation
associatedReferences	associatedReferences

Además se añadieron algunos atributos del DwC que son constantes para todo el conjunto de datos.

```
FishDB_CC.ready$license <- "CC BY-NC 4.0"
FishDB_CC.ready$rightsHolder <- "Cristian Correa, orcid.org/0000-0002-8608-6858"
FishDB_CC.ready$accessRights <- "not-for-profit use only"
# Add bibliographic citation where there is none (published
# papers prevail when available).
FishDB_CC.ready$bibliographicCitation[is.na(FishDB_CC.ready$bibliographicCitation) |
  trimws(FishDB_CC.ready$bibliographicCitation) == ""] <- "Correa, Cristian, and Maryse Boisjoly."
FishDB_CC.ready$datasetName <- "Correa-Boisjoly fish collection Version 2025-11-27"
FishDB_CC.ready$basisOfRecord <- "Occurrence"
```

6.1.5 Respaldo

```
write.csv(FishDB_CC.ready, "../data_sources/Correa-Boisjoly_Collection/Output_FishDatabase-Correa-Boisjoly",
  fileEncoding = "UTF-8", row.names = F)
```

```
saveRDS(FishDB_CC.ready, "./data_sources/Correa-Boisjoly_Collection/Output_FishDatabase_Correa-Boisjoly.r
```

6.2 Revisión de literatura C. Correa

Nombre corto del conjunto de datos: C.Correa.Lit.Review

Referencia: Correa, Cristian, B. Dyer, G. Gajardo, C. Garcia De Leaniz, C. Meier, H. Samaniego (2009) Rumbo a un sistema nacional de información geográfica de peces dulceacuícolas de Chile. Poster presentado en VI Congreso Sociedad Chilena de Limnología. Octubre 2009, Coyhaique. (Correa, Dyer, Garcia de Leaniz, Meier, & Samaniego, 2009)

Archivos: occurrences.csv, references.csv, site_coords_WGS84.csv, site_names.csv

Entre el período 2003-2009, uno de los autores de este reporte (CC) recabó, cual ratón de biblioteca, toda la literatura a su alcance sobre peces dulceacuícolas de Chile. Las bibliotecas consultadas incluyeron las principales Bibliotecas nacionales en Santiago, y algunas en Canadá, además de numerosos recursos online, préstamos interbibliotecarios, etc. A partir de este cuerpo de literatura, se obtuvieron datos de ocurrencias georeferenciadas que se incluyeron en este trabajo.

Nota: Esta revisión no pretende ser exhaustiva, y se presenta como fuente adicional de información potencialmente omitida por otras fuentes.

6.2.1 Lectura de datos

La base de datos original se encuentra organizada en una base de datos relacional en MS Access (toda la información no geográfica) y en QGIS (geoposicionamiento). Para este trabajo, se exportaron las tablas relevantes en un formato simple (*.csv), las cuales son importadas y procesadas a continuación para la producción de una sola tabla de ocurrencias con toda la información.

Tabla de nombres de sitios

```
site_names <- read.csv("./data_sources/FishGIS_metaDatabase/CorreaFishOccurrenceReview/site_names.csv",
  fileEncoding = "UTF-8", colClasses = "character", stringsAsFactors = FALSE)
# site_names %>% count(Site_ID) %>% filter(n > 1) # Good,
# unique

site_names <- site_names %>%
  select(Site_ID, Site_Name, Site_Precision, Notes, Years,
    Dates, Number_of_Dates, Samp_method, Number_of_fish,
    Fishing_gear, OLD_Primary_key, OLD_SITE_ID, OLD_ID, Review) %>%
  mutate(Site_ID = trimws(Site_ID))
```

Tabla de coordenadas geográficas (los puntos se digitalizaron previamente en un SIG)

```
# Site coordinates table.
site_coords_WGS84 <- read.csv("./data_sources/FishGIS_metaDatabase/CorreaFishOccurrenceReview/site_coord
site_coords_WGS84 <- site_coords_WGS84 %>%
  distinct() %>% # Make table unique
  relocate(Site_ID)
# site_coords_WGS84 %>% count(Site_ID) %>% filter(n > 1) # Good, unique

site_coords_WGS84 <- site_coords_WGS84 %>%
  mutate(decimalLongitude = round(as.numeric(decimalLongitude),5),
    decimalLatitude=round(as.numeric(decimalLatitude),5),
    Site_ID = trimws(Site_ID))
```

Tabla de ocurrencias

```
occurrences <- read.csv("./data_sources/FishGIS_metaDatabase/CorreaFishOccurrenceReview/occurrences.csv",
  fileEncoding = "UTF-8", colClasses = "character", stringsAsFactors = FALSE)
# occurrences %>% count(Species_ID) %>% filter(n > 1) #
# Good, unique

occurrences <- occurrences %>%
  mutate(Species_ID = trimws(Species_ID), Site_ID = trimws(Site_ID),
```

```
Ref_ID = trimws(Ref_ID))

# Se removieron filas que no aportaban registros de
# especies.
occurrences <- occurrences %>%
  filter(Species != "?")
```

Tabla de referencias bibliográficas

```
references <- read.csv("./data_sources/FishGIS_metaDatabase/CorreaFishOccurrenceReview/references.csv",
  fileEncoding = "UTF-8", colClasses = "character", stringsAsFactors = FALSE)
# references %>% count(Ref_ID) %>% filter(n > 1) # Good,
# unique

references$bibliographicCitation <- with(references, paste0(Author,
  " (", Year, ") ", Title, ". ", Journal.or.Editorial, " ",
  Vol..Pag, "."))

references <- references %>%
  select(Ref_ID, bibliographicCitation) %>%
  mutate(bibliographicCitation = bibliographicCitation %>%
    str_trim() %>%
    str_replace_all("(\\s*\\.\\.\\s*)+$", "") %>%
    ifelse(. == "" | is.na(.), ., str_c(., ".")), Ref_ID = trimws(Ref_ID))
```

Combinar tablas. A continuación se pobló la tabla de ocurrencias con información geográfica, datos de sitios de muestreo y referencias bibliográfica.

```
metaDB.CC <- occurrences %>%
  left_join(site_names, by = c(Site_ID = "Site_ID")) %>%
  left_join(site_coords.WGS84, by = c(Site_ID = "Site_ID")) %>%
  left_join(references, by = c(Ref_ID = "Ref_ID"))
```

La tabla de datos presentó 2020 filas u ocurrencias y 47 columnas o variables.

6.2.2 Filtrado área de estudio

Antes de filtrar el área de estudio se excluyeron 166 filas sin coordenadas geográficas. Si bien las coordenadas de muchas de estas filas se encuentran en el campo *Notas*, se comprobó que las 11 referencias afectadas ya fueron indexadas por otros conjuntos de datos.

```
metaDB.CC <- metaDB.CC %>%
  filter(!is.na(decimalLongitude))
```

Se extrajeron los datos dentro del área de estudio:

La Figura 3 muestra los datos filtrados espacialmente.

Luego de filtrar por el área de estudio, el conjunto de datos se redujo a 343 ocurrencias, registradas en 167 sitios, y obtenido de 30 referencias.

6.2.3 Homologación al DwC

Primero se acuñó la variable año del registro *year* basada en el primer año mencionado en *Years*, variable que ocasionalmente incluyó 2 o más años calendario.

```
# Enter approximate date for this reference including
# record from Lago Yulton and few others (Soto et al. 2006)
metaDB.CC.filtered$Years[metaDB.CC.filtered$Years == "Not specified (between 1990 and 2005)"] <- 1990

# Extract first year
metaDB.CC.filtered$year <- as.numeric(gsub("(^\\d{4}).*", "\\1",
  metaDB.CC.filtered$Years))
```




Fig. 3 Distribución de ocurrencias de peces de revisión de literatura (Correa et al. 2009). Los puntos rojos fueron excluidos por estar fuera del área de estudio indicada por el polígono.

Además se acuñó la variable `eventDate` que tolera varios formatos de fechas incluyendo intervalos de tiempo, según el DwC.

```
metaDB.CC.filtered <- metaDB.CC.filtered %>%
  mutate(eventDate = sapply(Years, function(x) {
    if (is.na(x) || str_trim(x) == "")
      return(NA_character_)

    yrs <- str_extract_all(x, "\\d{4}")[[1]]
    yrs <- sort(unique(as.integer(yrs)))

    if (length(yrs) == 0) {
      NA_character_
    } else if (length(yrs) == 1) {
      as.character(yrs[1])
    } else {
      paste0(min(yrs), "/", max(yrs) + 1)
    }
  }))
```

Luego se guardó información que no calza bien con el DwC en una nueva variable `eventRemarks`. Esta incluye una idea de la precisión de la geolocalización. (No se usaron variables tales como `coordinateUncertaintyInMeters` o `coordinatePrecision` porque el formato narrativo no concuerda con las definiciones del DwC.)

```
metaDB.CC.filtered$eventRemarks <- with(metaDB.CC.filtered, ifelse(Site_Precision !=
  "", paste(Years, Notes.x, "Geolocation:", Site_Precision),
  paste(Years, Notes.x)))
```

Se seleccionaron las columnas con información relevante y se homologaron con el DwC sustituyendo sus nombres.

```
metaDB.CC.filtered <- metaDB.CC.filtered %>%
  select(Species_ID, decimalLongitude, decimalLatitude, Site_Name,
         Species, year, eventDate, bibliographicCitation, eventRemarks)

colnames(metaDB.CC.filtered) <- recode(colnames(metaDB.CC.filtered),
  Species_ID = "occurrenceID", decimalLongitude = "decimalLongitude",
  decimalLatitude = "decimalLatitude", Site_Name = "locality",
  Species = "scientificName", year = "year", eventDate = "eventDate",
  bibliographicCitation = "bibliographicCitation", eventRemarks = "eventRemarks")
```

Se añadió un prefijo a occurrenceID para identificar el conjunto de datos.

```
metaDB.CC.filtered <- metaDB.CC.filtered %>%
  mutate(occurrenceID = paste0("CCorrea.Lit.Review.", occurrenceID))
```

Además se añadieron algunos atributos del DwC que son constantes para todo el conjunto de datos.

```
metaDB.CC.filtered$license <- "CC BY-NC 4.0"
metaDB.CC.filtered$datasetName <- "Literature review dataset of Chilean freshwater and diadromous f."
metaDB.CC.filtered$basisOfRecord <- "Occurrence"
```

6.2.4 Corrección de errores

Se identificaron un número de errores (de geolocalización, de nombres de localidades, etc.) y se corrigieron.

```
# Locality 'Laguna Ventisquero (estero Ventisquero)',
# change coordinates to -48.250000, -73.591667, moving
# point closer to the fiord in another basin.

fix <- metaDB.CC.filtered %>%
  transmute(fix = (decimalLatitude == -47.47356 & decimalLongitude ==
    -73.29885)) %>%
  pull()

metaDB.CC.filtered <- metaDB.CC.filtered %>%
  mutate(decimalLongitude = ifelse(fix, -73.59167, decimalLongitude),
    decimalLatitude = ifelse(fix, -48.25, decimalLatitude))

# Change Locality from Lago Risopatrón to Río Simpson,
# after reviewing the actual paper

fix <- metaDB.CC.filtered %>%
  transmute(fix = (decimalLatitude == -45.43213 & decimalLongitude ==
    -72.41295)) %>%
  pull()

metaDB.CC.filtered <- metaDB.CC.filtered %>%
  mutate(locality = ifelse(fix, "Río Simpson", locality))
rm(fix)

# Change coordinates to the site where the historical Río
# Pratt Hatchery was located.

fix <- metaDB.CC.filtered %>%
  transmute(fix = (decimalLatitude == -52.68588 & decimalLongitude ==
    -72.01994)) %>%
  pull()

metaDB.CC.filtered <- metaDB.CC.filtered %>%
  mutate(decimalLongitude = ifelse(fix, -72.73421, decimalLongitude),
    decimalLatitude = ifelse(fix, -51.56258, decimalLatitude))
rm(fix)
```

6.2.5 Respaldo

```
write.csv(metaDB.CC.filtered, "./data_sources/FishGIS_metaDatabase/Output_CCorreaLitReview.csv",
  fileEncoding = "UTF-8", row.names = F)

saveRDS(metaDB.CC.filtered, "./data_sources/FishGIS_metaDatabase/Output_CCorreaLitReview.rds")
```

6.3 Revisión de literatura M. Aguilar

Nombre corto del conjunto de datos: MAguilar.Lit.Review

Referencia: Aguilar-González, Marilyn (2023) Recopilación bibliográfica de ocurrencia de peces en la Patagonia del proyecto Priorización de Cuencas para la Conservación en Patagonia. Programa Austral Patagonia (ProAP) de The Pew Charitable Trusts. Coyhaique. (Aguilar, 2023)

Archivo: BD referencias (2022-2023).xlsx

Esta base de datos fue elaborada por Marilyn Aguilar González en el marco del Proyecto *Priorización de Cuencas para la Conservación en Patagonia**, liderado por Brian Reid y Anna Astorga del CIEP, y financiado por el Programa Austral Patagonia (ProAP) de la Universidad Austral de Chile y The Pew Charitable Trusts.

La información recopilada fue aunada en una misma planilla maestra considerando la nomenclatura de campos del Darwin Core para los datos compilados.

Algunas consideraciones sobre los datos recopilados:

1.- La información recopilada se basó en una revisión de publicaciones científicas de libre acceso e información publicada por fuentes confiables de carácter oficial (ej. Ministerio de Medio Ambiente), mediante búsqueda por especie, familia, grupo taxonómico, origen (nativa/introducida) y área de interés (Patagonia chilena y argentina).

2.- Algunas publicaciones no explicitaban el listado de coordenadas, solo mencionaban los sitios de estudio o incluían un rango de coordenadas (ej. Bravo et al. 2019; Bravo et al. 2022; Chalde et al. 2016; Monzón-Argüello et al. 2014; Muñoz et al. 2022; Schröder y Garcia de Leaniz, 2011). Sin embargo, poseían figuras del área de estudio que podían georreferenciar. Por lo tanto, dichas figuras se proyectaron en ArcGIS y luego se obtuvieron las coordenadas de los puntos de interés.

3.- Para la publicaciones que no contaban con fecha específica para cada registro pero mas bien un rango de fechas para la totalidad de los registros, se tomó la primera fecha mencionada, y se aplicó para todos los registros.

4.- Sólo se llenaron los atributos para los cuales se encontró información, y muchos registros resultaron incompletos.

6.3.1 Lectura de datos

```
RevAguilar <- readxl::read_xlsx("./data_sources/MAguilar_review/MAguilar_review2023.xlsx",
  sheet = 1, col_types = "text")

# Note that RevAguilar$references ==
# RevAguilar$associatedReferences, keep only the former.
RevAguilar <- RevAguilar %>%
  select(-associatedReferences) %>%
  mutate(individualCount = as.numeric(individualCount), decimalLatitude = as.numeric(decimalLatitude),
    decimalLongitude = as.numeric(decimalLongitude))
```

6.3.2 Homologación al DwC

Este conjunto de datos fue estandarizado al formato DwC casi desde un principio, por lo que casi no se requirieron cambios. Sin embargo, fue necesario estandarizar poblar `occurrenceID` con un identificador único y estandarizar atributos relativos a fechas. En particular, en los casos donde se reportaron rangos de

años, se usó el año inicial en el campo `year` (código abajo) y se mantuvo el rango original en `eventDate` (formato estandar DwC) y `verbatimEventDate` (inalterado).

Para `OccurrenceID` se concadenó un prefijo para identificar el conjunto de datos y un número único que este tenía indexado en `catalogNumber`

```
RevAguilar <- RevAguilar %>%
  mutate(occurrenceID = paste0("MAguilar.Lit.Review.", catalogNumber)) %>%
  relocate(occurrenceID)
```

Estandarización de fechas

```
library(dplyr)
library(stringr)

RevAguilar <- RevAguilar %>%
  mutate(day = ifelse(verbatimEventDate == "April 7{12 2004", "07", day)) %>%
  mutate(day = ifelse(verbatimEventDate == "March 13{24 2004", "13", day)) %>%
  mutate(
    # First, extract all 4-digit years from eventDate
    years = str_extract_all(year, "\\d{4}"),
    n_years = lengths(years),

    # Create new eventDate based on conditions
    eventDate = case_when(

      # If multiple years exist, paste first/last with /
      n_years >= 2 ~ paste0(sapply(years, "first"), "/", sapply(years, "last")),

      # Otherwise, build from year, month, day fields
      !is.na(year) & !is.na(month) & !is.na(day) ~
        sprintf("%04d-%02d-%02d", as.integer(year), as.integer(month), as.integer(day)),

      !is.na(year) & !is.na(month) ~
        sprintf("%04d-%02d", as.integer(year), as.integer(month)),

      !is.na(year) ~
        sprintf("%04d", as.integer(year)),

      # Keep original if none of the conditions apply
      TRUE ~ year) ) %>% select(-years, -n_years) # Remove temporary columns

# Remove a few trailing NAs produced by day ranges (fixed above though).
RevAguilar$eventDate <- sub("-NA$", "", RevAguilar$eventDate)

RevAguilar <- RevAguilar %>% mutate(year = str_extract(eventDate, "\\d{4}") %>% as.integer())

# Check results
# RevAguilar %>% select(year, month, day, eventDate) %>% distinct()
```

6.3.3 Filtrado área de estudio

No fue necesario aplicar un filtro espacial porque el área de estudio del conjunto de datos coincide con el área de estudio de este proyecto (Figura 4).

Además se añadieron algunos atributos del DwC que son constantes para todo el conjunto de datos.

```
RevAguilar.filtered$license <- "CC BY-NC 4.0"
RevAguilar.filtered$datasetName <- "Aguilar-González, Marilyn (2023) Recopilación bibliográfica de"
```




Fig. 4 Distribución de ocurrencias de peces según revisión bibliográfica de Marilyn Aguilar (2003).

6.3.4 Respaldo

```
write.csv(RevAguilar.filtered, "../data_sources/MAguilar_review/Output_MAguilar_review2023.csv",
          fileEncoding = "UTF-8", row.names = F)

saveRDS(RevAguilar.filtered, "../data_sources/MAguilar_review/Output_MAguilar_review2023.rds")
```

6.4 Base de datos Ministerio del Medio Ambiente de Chile

Nombre corto del conjunto de datos: MMA.continental.fishes

Nombre del conjunto de datos: GBIF.MMA (versión publicada en GBIF el 2023/12/13)

Referencia: Habit, E., Contreras, L., Dyer, B.S., Correa, C., Naretto, J., Contreras, V., Amaya, L., and Villagran. 2023. Fauna Íctica Nativa Continental de Chile. Ministerio del Medio Ambiente de Chile, Occurrence dataset <https://doi.org/10.15468/cxb957> accessed via GBIF.org on 2025-10-17. (Habit et al., 2023)

Archivo: BD_original_observaciones.xls

Archivo: GBIF.MMA.csv

El Ministerio del Medio Ambiente (MMA) hace años atrás (2015-2017) impulsó un esfuerzo colaborativo para producir un libro titulado *Peces nativos de aguas continentales de Chile* (280 páginas aprox.), que además llevaba anexo una base de datos de ocurrencias de peces de agua dulce. Leisy Stephanie Amaya Montano, División Recursos Naturales y Biodiversidad del MMA, era la coordinadora de este proyecto (bajo la jefatura de Alejandra Figueroa Fernández).

En la producción del libro y la base de datos estaba colaborando Gloria Arratia (KU), E. Habit (Centro EULA), I. Vila (Laboratorio de Limnología de la Universidad de Chile), M. Contreras (Centro de Ecología Aplicada), Cristián Correa (UACH), Bryan Dyer (UV), Claudio Quezada (UCh) y otros. Lamentablemente este esfuerzo nunca se concretó, a pesar de haberse alcanzado al menos un 70% de avance.

Sin embargo, se publicó la base de datos en GBIF el 13 de diciembre del 2023. El conjunto de datos publicado se llama: *Fauna Íctica Nativa Continental de Chile*. Al publicar la base de datos a la plataforma GBIF, algunos campos importantes para la trazabilidad de los registros, tales como `locality` o `bibliographicCitation` no fueron indexados de manera óptima. Por esta razón, en esta instancia, se

aprovechó de la oportunidad para completar los registros con la información correspondiente disponible en la base de datos original del MMA.

6.4.1 Lectura de datos

Importar la base de datos original:

```
MMA <- readxl::read_xls("./data_sources/GBIF_MMA/BD_original_observaciones.xls",
  col_types = "text")

MMA <- MMA %>%
  mutate(Lat_correg_2 = as.numeric(Lat_correg_2), Long_correg_2 = as.numeric(Long_correg_2),
    NumIndiv = as.numeric(NumIndiv))
```

Importar la misma base de datos pero la versión obtenida de GBIF:

```
GBIF_MMA <- read.delim("./data_sources/GBIF_MMA/GBIF_MMA.csv")
```

6.4.2 Comparación de versiones

```
cat("Does the two tables have the sanme number of rows?", nrow(MMA) ==
  nrow(GBIF_MMA))
```

```
## Does the two tables have the sanme number of rows? TRUE
```

```
# Check dimensions dim(GBIF_MMA) dim(MMA)
```

```
# Check column names sort(names(GBIF_MMA)) sort(names(MMA))
```

```
# # Compare column names sort(setdiff(names(MMA),
# names(GBIF_MMA))) # Columns in MMA but not in GBIF_MMA
# sort(setdiff(names(GBIF_MMA), names(MMA))) # Columns in
# GBIF_MMA but not in MMA intersect(names(GBIF_MMA),
# names(MMA)) # Common columns
```

Mismo número de registros y varias pruebas adicionales confirma que se trata de la misma base de datos, aunque solo un nombre de columna (entre decenas) coincide entre las dos bases de datos. Esta diferencia se reduce una vez que los datos de MMA son homologados al DwC más abajo. Comenzamos trabajando con la base de datos original filtrada para el área de estudio, para homologarla al formato DwC y luego añadirle identificadores provenientes de la versión de GBIF.

Filtrado área de estudio

Se extrajeron los datos dentro del área de estudio.

```
pts <- SpatialPointsDataFrame(data = MMA, coords = MMA[, c("Long_correg_2",
  "Lat_correg_2")], proj4string = CRS("+init=epsg:4326"))

withinAE <- !is.na(sp::over(pts, sp_poly, returnList = F))
MMA_AE <- MMA[withinAE, ]
```

La Figura 5 muestra un mapa con los datos filtrados espacialmente.

6.4.3 Homologación al DwC

Antes de homologar fue necesario estandarizar y combinar atributos relativos a fechas, fuentes de información y localidad.

Estandarización de fechas.

```
tmp <- MMA_AE %>%
  select(AnoCol, MesCol, DiaCol, RangoCol) %>%
  distinct()

fecha <- MMA_AE %>%
```




Fig. 5 Distribución de ocurrencias de peces según base de datos MMA. Los puntos rojos fueron excluidos por estar fuera del área de estudio indicada por el polígono.

```
select(AnoCol, MesCol, DiaCol, RangoCol)

# Replace unexpected values by NAs
fecha$AnoCol <- gsub("NA", NA, fecha$AnoCol)
fecha$MesCol <- gsub("NA", NA, fecha$MesCol)
fecha$MesCol <- gsub("44044", NA, fecha$MesCol)
fecha$DiaCol <- gsub("NA", NA, fecha$DiaCol)
fecha$DiaCol <- gsub("0", NA, fecha$DiaCol)

# Create a valid date field, with several accepted DwC
# formats
fecha <- fecha %>%
  # rowwise() %>%
mutate(fecha_Col = paste(AnoCol, MesCol, DiaCol, sep = "-")) %>%
  mutate(fecha_Col = gsub("-NA", "", fecha_Col)) %>%
  mutate(fecha_Col = gsub("NA", NA, fecha_Col)) %>%
  mutate(fecha_Col = ifelse(!is.na(RangoCol), gsub("\\s*-\s*",
    "/", RangoCol), fecha_Col)) %>%
  mutate(AnoCol = ifelse(is.na(AnoCol) & !is.na(fecha_Col),
    substr(fecha_Col, 1, 4), AnoCol))

# Inspect fecha %>% distinct() # Good!

# Keep standardized dates
MMA_AE$fecha_Col <- fecha$fecha_Col
MMA_AE$AnoCol <- fecha$AnoCol
```

La estandarización de fuentes de información se hizo en etapas para (i) reducir sinónimos bajo los campos OrigenReg y FuenteReg; (ii) combinar estos dos campos que fueron transformados en una versión preliminar de bibliographicCitation, y (iii) curado manual en una planilla de los valores únicos de esta

versión preliminar para estandarizar referencias bibliográficas y referencias asociadas. (iv) Por último, esta planilla fue utilizada para actualizar `bibliographicCitation` y `associatedReferences`.

```
# Merging synonyms
MMA_AE <- MMA_AE %>%
  mutate(OrigenReg = recode(OrigenReg, `Base Datos EULA UdeC` = "Base de Datos EULA UdeC",
    `Base Datos` = "Base de Datos EULA UdeC"))
MMA_AE <- MMA_AE %>%
  mutate(FuenteReg = recode(FuenteReg, `Publicación, 2012` = "Unmack et al. 2012"))

# Combination of both fields
MMA_AE <- MMA_AE %>%
  rowwise() %>%
  mutate(OrigFuenteReg = paste0("OrigenReg: ", OrigenReg, ", FuenteReg: ",
    FuenteReg, " Estudio: ", Estudio))
MMA_AE$OrigFuenteReg <- gsub("OrigenReg: NA,", "", MMA_AE$OrigFuenteReg)
MMA_AE$OrigFuenteReg <- gsub("FuenteReg: NA,", "", MMA_AE$OrigFuenteReg)
MMA_AE$OrigFuenteReg <- gsub("FuenteReg: NA", "", MMA_AE$OrigFuenteReg)
MMA_AE$OrigFuenteReg <- gsub("Estudio: NA", "", MMA_AE$OrigFuenteReg)
MMA_AE$OrigFuenteReg <- trimws(MMA_AE$OrigFuenteReg)
```

Con la combinación de `OrigenReg`, `FuenteReg` y `Estudio` bajo `OrigFuenteReg` se generó una lista con valores únicos que fue exportada a una planilla de cálculo. Cada cadena de texto resultante fue revisada manualmente para 1) estandarizar el formato de las referencias bibliográficas, y según la necesidad, 2) asignar la información correspondiente a dos campos del DwC: `bibliographicCitation` y `associatedReferences`. Estas mejoras se encuentran en el archivo `./data_sources/GBIF_MMA/bibliographicCitation_fix.csv`, que a continuación se importa para actualizar los valores en `MMA_AE`.

```
refFix <- read.csv("./data_sources/GBIF_MMA/bibliographicCitation_fix.csv",
  ) %>%
  select(-ID)

MMA_AE <- MMA_AE %>%
  left_join(refFix, by = join_by(OrigFuenteReg))
```

En la Tabla 5 se presentan las distintas referencias encontradas combinando campos previo al curado manual (`OrigFuenteReg`) y estandarización DwC (`bibliographicCitation`, `associatedReferences`).

id	OrigFunteReg	bibliographicCitation
1	OrigenReg: Zama, A., and Cárdenas, E. 1984. Introduction into Aysén Chile of the pacific salmon. N°9 Descriptive catalogue of marine and freshwater fishes from the Aysén region, southern Chile, with zoogeographical notes on fish fauna. Servicio Nacional de Pesca - Japanese International Cooperation Agency., FuenteReg: Servicio Nacional de Pesca (Puerto Aysen)	Zama, A., and Cárdenas, E. 1984. Introduction into Aysén Chile of the pacific salmon.
2	OrigenReg: Zama, A., and Cárdenas, E. 1984. Introduction into Aysén Chile of the pacific salmon. N°9 Descriptive catalogue of marine and freshwater fishes from the Aysén region, southern Chile, with zoogeographical notes on fish fauna. Servicio Nacional de Pesca - Japanese International Cooperation Agency. McDowall, R.M., and Nakaya, K. 1987. Identity of the galaxioid fishes of the genus <i>Aplochiton</i> Jenyns from southern Chile. Japan Journal of Ichthyology 34: 377–383., FuenteReg: Instituto de la Patagonia, Punta Arenas	Zama, A., and Cárdenas, E. 1984. Introduction into Aysén Chile of the pacific salmon.
3	OrigenReg: McDowall, R.M., and Nakaya, K. 1988. Morphological divergence in the two species of <i>Aplochiton</i> Jenyns (Salmoniformes: Aplochitonidae): a generalist and a specialist. Copeia 1: 233–236., FuenteReg: Laboratory of Marine Zoology, Hokkaido University (HUMZ)	McDowall, R.M., and Nakaya, K. 1988. Morphological divergence in the two species of <i>Aplochiton</i> Jenyns (Salmoniformes: Aplochitonidae): a generalist and a specialist. Copeia 1: 233–236.
4	OrigenReg: Alò, D., Correa, C., Arias, C., and Cardenas, L. 2013. Diversity of <i>Aplochiton</i> Fishes (Galaxiidae) and the Taxonomic Resurrection of <i>A. marinus</i> . PLoS ONE. doi/10.1371/journal.pone.0071577., FuenteReg: Museo Nacional de Historia Natural de Chile	Alò, D., Correa, C., Arias, C., and Cárdenas, L. 2013. Diversity of <i>Aplochiton</i> fishes.
5	OrigenReg: Alò, D., Correa, C., Arias, C., and Cardenas, L. 2013. Diversity of <i>Aplochiton</i> Fishes (Galaxiidae) and the Taxonomic Resurrection of <i>A. marinus</i> . PLoS ONE. doi/10.1371/journal.pone.0071577.,	Alò, D., Correa, C., Arias, C., and Cárdenas, L. 2013. Diversity of <i>Aplochiton</i> fishes.
6	OrigenReg: CEA para ENDESA, FuenteReg: Base de datos CEA 2015	CEA para ENDESA, Base de datos CEA 2015
7	OrigenReg: Base de Datos EULA UdeC, FuenteReg: Base Datos 2007	Base Datos EULA UdeC, Base Datos 2007
8	OrigenReg: Base de Datos EULA UdeC, FuenteReg: Base Datos 2009	Base Datos EULA UdeC, Base Datos 2009
9	OrigenReg: Base de Datos EULA UdeC, FuenteReg: Base Datos 2013	Base Datos EULA UdeC, Base Datos 2013
10	OrigenReg: Base de Datos EULA UdeC, FuenteReg: Base Datos 2008	Base Datos EULA UdeC, Base Datos 2008
11	FuenteReg: McDowall & Nakaya 1987	McDowall, R.M., and Nakaya, K. 1987. Identity of the galaxioid fishes of the genus <i>Aplochiton</i> Jenyns from southern Chile.
12	FuenteReg: Campos et al. 1984	Campos, H. 1984. Gonswana and Neotropical Galaxioid fish biogeography. In Evolutionary Biology of Fishes, Vol. 1, pp. 1–10. Academic Press, New York.
13	FuenteReg: McDowall 1971a	McDowall, R.M. 1971. Fishes of the family Aplochitonidae. Journal of The Royal Society of New Zealand 1: 1–10.
14	FuenteReg: Moorman et al. 2009	Moorman, M.C. 2007. The Conservation Implications of Introduced Trout and Brown Salmon in Chile. Conservation Biology 21: 1–10.
15	OrigenReg: Base de Datos EULA UdeC, FuenteReg: Base Datos 2005	Base Datos EULA UdeC, Base Datos 2005
16	OrigenReg: Base de Datos EULA UdeC, FuenteReg: Base Datos 2006	Base Datos EULA UdeC, Base Datos 2006
17		
18	FuenteReg: Eigenmann 1927 Estudio: Campos et al. 1993b	Eigenmann, C.H. 1928. The fresh-water fishes of Chile. Memoirs of the National Academy of Sciences 1: 1–10.
19	FuenteReg: Fowler 1951 Estudio: Campos et al. 1993b	Fowler, H. 1951. Analysis of the fishes of Chile. Revista Chilena de Historia Natural 24: 1–10.

20	FuenteReg: Gunther 1980 Estudio: Campos et al. 1993b	Günther, A.C.L.G. 1880. An introduction to the study of fishes. Adam & Cha
21	FuenteReg: Valenciennes 1833 Estudio: Arratia et al. 1981	Cuvier, G., Cuvier, G., Axelrod, H.R., Baird, S.F., Valenciennes, Koninklijk Z
22	FuenteReg: Gonzalez 2005	González, J. 2005. Evaluación de interferencias tróficas entre truchas y peces r
23	FuenteReg: Campos et al. 1996	Campos, H., Gavilan, J., Murillo, V., and Alarcon, P. 1996. Presencia de Chei
24	OrigenReg: Estudio peces CEA, FuenteReg: Entrevista Jorge Parra	Estudio peces CEA, Entrevista Jorge Parra
25	OrigenReg: Base de Datos EULA UdeC, FuenteReg: Base Datos 2014	Base Datos EULA UdeC, Base Datos 2014
26	OrigenReg: Base Datos CEA 2015,	Base Datos CEA 2015
27	FuenteReg: Murillo & Ruiz 2002 Estudio: Vila et al. 2006	Murillo, V., and Ruiz, V.H. 2002. El puye Galaxias globiceps Eigenmann 1927
28	OrigenReg: Líneas bases XI CEA Ltda. Agosto 2015, FuenteReg: Líneas bases XI CEA Ltda. Agosto 2015	Líneas bases XI CEA Ltda. Agosto 2015
29	OrigenReg: Publicación, FuenteReg: Vila et al. 1999. Ictiofauna en los sistemas límnicos de la Isla Grande, Tierra del Fuego, Chile	Vila, I., Fuentes, L., and Saavedra, M. 1999. Ictiofauna en los sistemas límnicos
30	FuenteReg: Campos & Ortiz 1992 Estudio: Campos et al. 1993b	Campos, H., and Ortiz, J.C. 1992. Peces, Anfibios y Reptiles de Torres del Pa
31	FuenteReg: Campos et al. 1984 Estudio: Campos et al. 1993b	Campos, H. 1984. Gonswana and Neotropical Galaxioid fish biogeography. In
32	FuenteReg: Venegas 2005	Venegas 2005
33	FuenteReg: Vila et al. 1999	Vila, I., Fuentes, L., and Contreras, M. 1999. Peces límnicos de Chile. Boletín
34	OrigenReg: Base de Datos EULA UdeC, FuenteReg: Base Datos 2009 2010	Base Datos EULA UdeC, Base Datos 2009 2010
35	OrigenReg: Base de Datos EULA UdeC, FuenteReg: Base Datos 2011	Base Datos EULA UdeC, Base Datos 2011
36	OrigenReg: Fishnet2, FuenteReg: Colecta BS Dyer	Fishnet2, Colecta BS Dyer
37	FuenteReg: McDowall 1971b Estudio: Ruiz & Marchant 2004	McDowall, R.M. 1971. The Galaxiid fishes of South America. Zoological Jour
38	OrigenReg: Publicación, FuenteReg: Unmack et al 2009	Unmack, P.J., Habit, E.M., and Johnson, J.B. 2009. New records of Hatcheria
39	FuenteReg: Unmack et al. 2009a	Unmack, P., Bennin, A., Habit, E., Victoriano, P., and Johnson, J. 2009. Imp
40	FuenteReg: Unmack et al. 2009b	Unmack, P.J., Habit, E.M., and Johnson, J.B. 2009. New records of Hatcheria
41	FuenteReg: Campos et al. 1998 Estudio: Ruiz & Marchant 2004	Campos, H., Dazarola, G., Dyer, B.S., Fuentes, L., Gavilán, J.F., Huaquín, L.
42	FuenteReg: Unmack et al. 2012	Unmack, P.J., Barriga, J.P., Battini, M.A., Habit, E.M., and Johnson, J.B. 20
43	OrigenReg: Francisco J. Neira 1984,	Neira, F.J. 1984. Biomorfología de las lampreas parásitas Geotria australis Gr
44	FuenteReg: Perugia 1891 Estudio: Campos et al. 1993b	Perugia, A. 1891. Appunti sopra alcuni pesci sud-americani conservati nel Mu
45	OrigenReg: Unmack et al 2009,	Unmack, P.J., Habit, E.M., and Johnson, J.B. 2009. New records of Hatcheria
46	FuenteReg: Eigenmann 1927	Eigenmann, C.H. 1928. The fresh-water fishes of Chile. Memoirs of the Nation

También se combinaron campos `verbatimLocality`, `DescrLoc`, y `SSCuenca_correg` para crear `locality` y `eventRemarks` del DwC. El campo de MMA `locality` se omitió por ser redundante e incompleto.

```
# locality (recycling the existing locality column)
tmp <- MMA_AE[, c("verbatimLocality", "DescrLoc", "SSCuenca_correg")]
MMA_AE$locality <- apply(tmp, 1, function(x) {
  paste0(unique(x), collapse = ". ")
})
MMA_AE$locality <- gsub(pattern = "NA. ", replacement = "", MMA_AE$locality)
MMA_AE$locality <- paste0(MMA_AE$locality, ".")
```

Se rescató información de los campos `Mandante` y `Estacion` para incorporarla en `eventRemarks`.

```
# eventRemarks (MandanteEstacion was renamed to
# eventRemarks below)
MMA_AE$eventRemarks <- paste0("Mandante: ", MMA_AE$Mandante,
  " | Estacion: ", MMA_AE$Estacion)
MMA_AE$eventRemarks <- gsub("Mandante: NA | Estacion: NA", "",
  MMA_AE$eventRemarks)
MMA_AE$eventRemarks[MMA_AE$eventRemarks == "|"] <- ""
```

La combinación de los dos campos Instit y Institución aporta BBDD Proyecto Ictiofauna 2015 generó una lista de valores únicos que fue exportada a una planilla de cálculo. Cada cadena de texto resultante fue revisada manualmente para asignar la información correspondiente entre los campos del DwC institutionID y eventRemarks. Estas mejoras se encuentran en el archivo ./data.sources/GBIF_MMA/institutionID_fix.csv, que a continuación se importa para actualizar los valores en MMA_AE.

```
refFix <- read.csv("./data.sources/GBIF_MMA/institutionID_fix.csv",
)

# Just a convenient function to concatenate cleanly below.
clean_pipes <- function(x) {
  sapply(strsplit(x, "\\|"), function(parts) {
    parts <- trimws(parts)
    parts <- parts[parts != ""]
    paste(parts, collapse = " | ")
  }, USE.NAMES = FALSE)
}

MMA_AE <- MMA_AE %>%
  mutate(InstitInstitu = paste(Instit, `Institución aporta BBDD \nProyecto Ictiofauna 2015`)) %>%
  # select(InstitInstitu, eventRemarks) %>%
left_join(select(refFix, InstitInstitu, institutionID, eventRemarks),
  by = join_by(InstitInstitu)) %>%
  mutate(eventRemarks = clean_pipes(paste(eventRemarks.y, eventRemarks.x,
    sep = " | "))) %>%
  select(-eventRemarks.y, -eventRemarks.x) %>%
  distinct()
```

El TipoReg fue renombrado a basisOfRecord y salvo por los etiquetados “Voucher”, todos los registros se indexaron como “Occurrence”. Voucher fue renombrado a “PreservedSpecimen”.

```
MMA_AE <- MMA_AE %>%
  mutate(basisOfRecord = ifelse(TipoReg == "Voucher", "PreservedSpecimen",
    "Occurrence"))
```

La variable Precision del MMA contenía el valor “GPS” en cientos de registros, indicando que las coordenadas geográficas provenían de lecturas de GPS. No obstante, las coordenadas, expresadas en grados decimales, presentaban solo tres decimales, lo que implica una resolución espacial aproximada del orden de 100 m. En consecuencia, para estandarizar esta información según DwC, los registros con Precision = “GPS” fueron homologados a coordinateUncertaintyInMeters = 100.

```
MMA_AE <- MMA_AE %>%
  mutate(coordinateUncertaintyInMeters = ifelse(Precision ==
    "GPS", 100, NA_real.))
```

Se seleccionaron las columnas con información relevante y se homologaron con el DwC sustituyendo sus nombres en los casos pendientes.

```
MMA_AE <- MMA_AE %>% mutate(
  occurrenceID          = fila,
  eventDate             = fecha_Col, # processed above
  year                  = AnoCol,    # processed above
  locality              = locality,  # processed above
  decimalLongitude      = Long_correg_2,
  decimalLatitude       = Lat_correg_2,
  scientificName        = NomCient,
  bibliographicCitation = bibliographicCitation, # processed above
  associatedReferences   = associatedReferences, # processed above
  eventRemarks         = eventRemarks,        # processed above
  individualCount       = NumIndiv,
  samplingProtocol      = TipoMetodo,
  recordedBy            = Colector,
  coordinateUncertaintyInMeters = coordinateUncertaintyInMeters, # above
```

```
basisOfRecord      = basisOfRecord, # processed above
institutionID      = institutionID, # processed above
  .keep = "none" )
```

6.4.4 Asignación de IDs de la versión GBIF

Si bien los datos del MMA ya fueron publicados en GBIF en formato DwC y se bajaron de esa plataforma (tabla GBIF_MMA), estos están incompletos, faltaron campos importantes tales como `locality` y `bibliographicCitation`. Por lo tanto, se optó por usar la base de datos original del MMA manipulada en este documento (i.e., MMA), añadiéndole los campos `gbifID`, `datasetKey`, y `occurrenceID` provenientes de GBIF_MMA de modo de preservar la trazabilidad de la publicación original en GBIF.

Para asociar, una a una, las ocurrencias de la tabla MMA con la de la table GBIF_MMA, se usó como clave el campo `occurrenceID` (proveniente de `fila` en el set de datos original) luego de hacerlo compatible con `occurrenceID` de GBIF_MMA añadiéndole el prefijo “MMA:ICT:”, seguido de siete dígitos correspondiendo al número de fila.

```
MMA_AE$occurrenceID <- as.numeric(MMA_AE$occurrenceID)
MMA_AE <- MMA_AE %>%
  mutate(occurrenceID = sprintf("MMA:ICT:%07d", occurrenceID)) %>%
  relocate(occurrenceID)
head(MMA_AE$occurrenceID)
```

```
## [1] "MMA:ICT:0000002" "MMA:ICT:0000003" "MMA:ICT:0000004" "MMA:ICT:0000005"
## [5] "MMA:ICT:0000007" "MMA:ICT:0000008"
```

Usando `occurrenceID` para relacionar ambos sets de datos, se extrajo `gbifID` de GBIF_MMA y se le añadió a MMA (o MMA_AE) en el campo `otherCatalogNumbers`.

```
MMA_AE <- MMA_AE %>%
  left_join(GBIF_MMA %>%
    select(occurrenceID, gbifID), by = "occurrenceID") %>%
  mutate(otherCatalogNumbers = paste0("gbifID:", gbifID)) %>%
  select(-gbifID)
```

Además se añadieron identificadores del conjunto de datos proveniente GBIF_MMA en el caso de `datasetKey`, así como licencia de acceso también copiada de GBIF_MMA.

```
MMA_AE <- MMA_AE %>%
  mutate(datasetName = "Habit E, Vila I, Contreras L. M, Dyer B, Correa C, Naretto J, Contreras V,
    datasetID = "GBIF UUID: 45c3d8d2-7352-4dd1-aefd-c21e0b6b004e",
    license = "CC BY-NC 4.0", accessRights = "consultar con institución/autor")
```

6.4.5 Respaldo

```
write.csv(MMA_AE, "./data_sources/GBIF_MMA/Output_MMA_AE_GBIF_DwC.csv",
  fileEncoding = "UTF-8", row.names = F)

saveRDS(MMA_AE, "./data_sources/GBIF_MMA/Output_MMA_AE_GBIF_DwC.rds")
```

6.5 SUBPESCA: Primera base de datos

Hemos obtenido dos bases de datos aportadas por la Subsecretaría de Pesca y Acuicultura (SUBPESCA) que se analizan a continuación.

Además, existe un set de datos llamado “Base de datos biogeográfica del Fondo de Investigación Pesquera y de Acuicultura (1999-2019), Subsecretaría de Pesca y Acuicultura” publicado en 2023 ([vínculo](#)) con más de 3 millones de ocurrencias pero que no se analizó porque su área de estudio es el ambiente marino. Se confirmó que la composición taxonómica no incluye especies de interés.

Primer set de datos:

Nombre corsto del conjunto de datos: SUBPESCA.PecesContinetales2019

Referencia: SUBPESCA (2019) Sistematización de registros de peces de aguas continentales. Archivo: BDSubpesca_original.xlsx

Esta base de datos con registros hasta 2019 incluye un número de publicaciones científicas, informes de declaración y evaluación de impacto ambiental y posiblemente permisos de pesca de investigación. Viene con muchos errores, inconsistencias, formatos heterogéneos, etc., que han sido abordados y subsanados en la medida de lo posible.

```
SUBPESCA <- readxl::read_xlsx("./data_sources/SUBPESCA/SubpescaDB1/BDSubpesca_original.xlsx",
  col_types = "text", col_names = T, na = "NA")

SUBPESCA$decimalLatitude <- as.numeric(SUBPESCA$decimalLatitude)
SUBPESCA$decimalLongitude <- as.numeric(SUBPESCA$decimalLongitude)
SUBPESCA$ABUNDACIA <- as.numeric(SUBPESCA$ABUNDACIA)
```

Modificar el título de proyecto que posee un número ascendente al final, como producto de arrastre de celdas en excel.

```
SUBPESCA <- SUBPESCA %>%
  mutate(TITULO_PRO = if_else(grepl("EVALUACION Y SEGUIMIENTO DE LA SITUACION SANITARIA DE ESPECIES SI",
    TITULO_PRO), "EVALUACION Y SEGUIMIENTO DE LA SITUACION SANITARIA DE ESPECIES SILVESTRES EN AGUA",
    TITULO_PRO))
```

6.5.1 Manejo de referencias

Se combinaron seis campos para crear una versión cruda preliminar del atributo bibliographicCitation del DwC.

```
SUBPESCA$REVISTA <- gsub("ND", "", SUBPESCA$REVISTA)

SUBPESCA <- SUBPESCA %>%
  mutate(TITULO_PRO = if_else(stringr::str_to_upper(TITULO_PRO) ==
    TITULO_PRO, stringr::str_to_title(tolower(TITULO_PRO)),
    TITULO_PRO)) %>%
  mutate(bibliographicCitation = paste0(`AUTOR/EJECUTOR`, " (",
    AÑO_PUBLIC, ") ", TITULO_PRO, ". ", REVISTA, ", ", LINK)) %>%
  mutate(bibliographicCitation = ifelse(is.na(REVISTA), bibliographicCitation,
    `CITA (APA)`)) %>%
  mutate(bibliographicCitation = str_trim(str_remove_all(bibliographicCitation,
    "[\\.,;]?\\s*(\\b(NA|ND)\\b[\\s,]*)+$"))

# length(unique(SUBPESCA$bibliographicCitation))
```

El conjunto de datos presentó 90 referencias provenientes de estudios de impacto ambiental (consultores), artículos científicos y otros.

Muchos de los artículos científicos indexados contenían errores y omisiones tal como no registrar el año de las ocurrencias lo que genera dificultades en el procesamiento subsecuente en el capítulo *Consolidación del Atlas Ictiogeográfico*. Por lo tanto se optó por excluir todas las ocurrencias de este set de datos correspondientes a artículos científicos indexadas también en otros conjuntos de datos de mejor calidad (i.e. redundantes). Para esto, primero se exportó una planilla con las 90 referencias (bibliographicCitation), y esta planilla se editó manualmente añadiendo el campo Filter con valores 1 y 0 para referencias a incluir o excluir, respectivamente.

```
# Save the table of references edit it in the spreadsheet
# (done)

# tmp <- SUBPESCA %>% select(bibliographicCitation) %>%
# arrange() %>% unique() write.csv(tmp,
# './data_sources/SUBPESCA/SubpescaDB1/Subpesca_bibliographicCitation.csv')

# Import the table of references including the filter
# column added manually
```

```

filter <- read.csv("./data_sources/SUBPESCA/SubpescaDB1/Subpesca.bibliographicCitation.filter.csv",
  row.names = 1)

n_exclude <- SUBPESCA %>%
  left_join(filter, by = "bibliographicCitation") %>%
  filter(Filter == 0) %>%
  nrow()

SUBPESCA <- SUBPESCA %>%
  left_join(filter, by = "bibliographicCitation") %>%
  filter(Filter == 1)

```

En la planilla, de las 90 referencias, 30 se excluyeron (números un poco exagerados pues algunas referencias aparecían más de una vez bajo distinto formato). La aplicación de este filtro resultó en la exclusión de 335 ocurrencias provenientes de artículos científicos indexados en otros conjuntos de datos. La vasta mayoría de las referencias retenidas corresponden a ocurrencias reportadas por empresas consultoras en el marco del Sistema de Evaluación Ambiental (SEA). Se retuvieron 7176 ocurrencias.

6.5.2 Filtrado área de estudio

Primero se estandarizaron las coordenadas geográficas a grados decimales, y luego se filtró el área de estudio. Estos pasos se hicieron en un SIG (ArcGIS 10.8.2) antes de importar los datos (Marilyn Aguilar).

- De los puntos dentro del rango de interés (X-XII Región) de la base de datos Subpesca existieron 38 puntos UTM erróneos que tuvieron que ser incorporados manualmente al SIG, pasando en limpio los datos originales para poder corregir los errores.
 - 23 de estos (datos Econometric ID: 50214-50248) no tenían el 7mo dígito de la coordenada Norte y correspondían a datos de una DIA. De acuerdo con los datos originales de esta DIA (https://seia.sea.gob.cl/expediente/expedientesEvaluacion.php?modo=ficha&id_expediente=2132812956) sólo 20 puntos corresponden realmente a los datos originales.
 - 11 datos (ID: 31580-31584; todos *G. maculatus*) correspondían al paper de Delgado et al. (2019). Luego de revisar el paper se constató que eran 14 y no 11 puntos: 3 de estos de Zemlak et al. 2010; 9 de Gorski et al. 2018; y 2 datos no publicados anteriormente de Habit Lab.
 - 2 datos correspondientes al EIA Central de pasada Mediterraneo (https://seia.sea.gob.cl/expediente/expedientesEvaluacion.php?modo=ficha&id_expediente=6357086#-1) (ID: 25957 y 28720) que según documentación original son 4 datos (3 de *S. trutta* y 1 de *O. mykiss*).
 - 1 polígono Subcuenca 1152/Río Aviles (ID: 29153) (https://seia.sea.gob.cl/expediente/expedientesEvaluacion.php?modo=ficha&id_expediente=2128931266) que, de acuerdo con documentación original, no hay datos pues se dio termino anticipado al proyecto y en el expediente solo se menciona que se espera encontrar *O. mykiss* en el área de estudio pero no se realizó ningún estudio al respecto. Por esto, este punto se excluyó.
 - 1 dato erróneo (ID: 44711) que no se logró corroborar con la información original. No obstante, de acuerdo con la base de datos de Subpesca, es un dato que pertenece a la cuenca del Río Maullín así que no corresponde con nuestra área de estudio. Excluido.
- Asimismo, existieron 50 puntos erróneos de coordenadas tipo DM, las cuales tuvieron que ser ingresadas manualmente una vez corregidas:
 - 3 pertenecían a Aló et al. (2013) (ID: 31534-31536), luego de revisar el paper se corrigió a 7 puntos.
 - 35 de estos provenían de Ortiz-Sandoval et al. (2017) (ID: 31760-31794). Por lo tanto, los 61 puntos originales se extrajeron directamente del paper.




Fig. 6 Distribución de ocurrencias de peces de la base de datos de SUBPESCA.

- 12 correspondían a Bravo et al. (2019) sobre especies introducidas (ID: 31705-31716). Tras una revisión del paper se corrigió a 2 sitios de muestreo y 4 especies registradas por sitio.

En resumen se ingresaron manualmente 24 puntos UTM y 90 puntos en grados decimales (incluidos los 14 puntos de Delgado et al. 2019), provenientes de estos errores de la base de datos de Subpesca.

En cuanto a las columnas de “decimalLatitude”, y “decimalLongitude”, estas fueron calculadas una vez obtenidas las capas de coordenadas de la base de datos Subpesca en ArcGIS. Primero se pasaron las planillas excel a tablas de atributos y luego estas tablas de atributos fueron transformadas a datos con coordenadas grados decimales mediante el geoproceto “Convert Coordinate Notation (Data Management)”. Una vez hecho este proceso para las diferentes capas procesadas de acuerdo a las diferencias en coordenadas originales (DD, DMS, UTM, adicionales provenientes de errores), se realizó la fusión de capas para tener todos los datos en una misma planilla con sus coordenadas en grados decimales.

Una vez ingresados los datos en este análisis, se corrigieron 20 coordenadas intercambiadas ente latitud y longitud.

```
# Offending coordinates: OBJECTID %in% c(50214:50233)
SUBPESCA[SUBPESCA$OBJECTID %in% c(50214:50233), c("decimalLongitude",
  "decimalLatitude")] <- SUBPESCA[SUBPESCA$OBJECTID %in% c(50214:50233),
  c("decimalLatitude", "decimalLongitude")]
```

Mapa con datos filtrados espacialmente (Figura 6).

6.5.3 Selección de atributos

```
SUBPESCA <- SUBPESCA %>% select(OBJECTID,
  # FUENTE_BBDD
  # MANDANTE
  MES,
  `AÑO`,
  # HORA, # barely available
  COD_EST,
```

```

ESTE,
NORTE,
UTM,
DATUM,
NOMBRE_CIE,
TIPO_ARTE,
ABUNDACIA,
bibliographicCitation, # modified above
decimalLongitude, # coords normalized earlier
decimalLatitude)
# UNIDAD_ABUN
# CPUE
# UNIDAD_CPUE # These attributes aren't well curated

```

6.5.4 Estandarización de fechas

Se estandarizó la fecha de ocurrencia. La base de datos provista por SUBPESCA solo contemplaba los campos Mes y Año, y para la mayoría de los registros, estos campos estaban vacíos.

Por ahora, se reemplazaron los rangos de años por el primer año, los años cero por NAs, y los años y meses originales con formatos especiales se conservaron en `verbatimEventDate`.

```

SUBPESCA$MES <- gsub(pattern = "ND", replacement = NA, SUBPESCA$MES)

SUBPESCA <- SUBPESCA %>%
  mutate(Offending_month = ifelse(is.na(suppressWarnings(as.integer(MES))),
    MES, NA), Offending_year = ifelse(is.na(suppressWarnings(as.integer(AÑO))),
    AÑO, NA)) %>%
  mutate(MES = suppressWarnings(as.integer(MES)), AÑO = suppressWarnings(as.integer(AÑO)),
    verbatimEventDate = paste(Offending_year, Offending_month)) %>%
  mutate(AÑO = ifelse(!is.na(Offending_year), as.character(sapply(strsplit(Offending_year,
    "-"), `[[`, 1))), AÑO)) %>%
  mutate(AÑO = ifelse(AÑO == "0", NA, AÑO)) %>%
  mutate(AÑO = as.integer(AÑO)) %>%
  mutate(verbatimEventDate = gsub("NA", "", verbatimEventDate)) %>%
  mutate(verbatimEventDate = stringr::str_squish(verbatimEventDate)) %>%
  select(-Offending_month, -Offending_year)

```

6.5.5 Estandarización nombre científico

Se pasaron a minúsculas los nombres científicos, salvo por la primera letra de géneros.

```

SUBPESCA <- SUBPESCA %>%
  mutate(NOMBRE_CIE = stringr::str_to_sentence(NOMBRE_CIE)) %>%
  mutate(NOMBRE_CIE = stringr::str_squish(NOMBRE_CIE))

```

6.5.6 Homologación al formato DwC

Se renombraron las columnas para homologar,

```

SUBPESCA <- SUBPESCA %>%
  mutate(occurrenceID = paste0("SUBPESCA.PecesContinetales2019.",
    OBJECTID), catalogNumber = OBJECTID, month = MES, year = AÑO,
    locationRemarks = COD_EST, verbatimLatitude = ESTE, verbatimLongitude = NORTE,
    verbatimCoordinateSystem = UTM, verbatimSRS = DATUM,
    scientificName = NOMBRE_CIE, samplingProtocol = TIPO_ARTE,
    individualCount = ABUNDACIA, bibliographicCitation = bibliographicCitation,
    decimalLongitude = decimalLongitude, decimalLatitude = decimalLatitude,
    .keep = "none")

```

Además se añadió un identificador del conjunto de datos.

```
SUBPESCA <- SUBPESCA %>%
  mutate(datasetName = "SUBPESCA (2019) Sistematización de registros de peces de aguas continentales.",
    license = "CC NC-BY 4.0", accessRights = "Publicaciones científicas y estudios parte del SEA so
  ungroup()
```

6.5.7 Respaldo

```
write.csv(SUBPESCA, "./data_sources/SUBPESCA/SubpescaDB1/Output.SUBPESCA_DwC.csv",
  fileEncoding = "UTF-8", row.names = F)

saveRDS(SUBPESCA, "./data_sources/SUBPESCA/SubpescaDB1/Output.SUBPESCA_DwC.rds")
```

6.6 SUBPESCA: Segunda base de datos

Nombre corto del conjunto de datos: SUBPESCA.PescaInvestigación2012-2023.

Referencia: SUBPESCA (2023) Resultados de pesca de investigación de peces de aguas continentales en el período 2012-2023.

Archivo: BD_Subpesca_PINV_2012_2023_original.xlsx

Estos datos fueron adquiridos mediante solicitud bajo Ley de Transparencia a la Subsecretaría de Pesca y Acuicultura (SUBPESCA), como respuesta a consulta de acceso a la información pública CI: AH002T-0005627, solicitada por Marilyn Aguilar González en 2023. Dicha solicitud requirió de un proceso de subsanación (gestionado por Macarena Covarrubias), acotando el período de Permisos de Pesca de Investigación a los resultados de proyectos desde el año 2012 hasta el otoño 2023.

Se recibieron 113 carpetas organizadas por resolución de aceptación de cada permiso de pesca (los datos no estaba ordenados en una tabla). De estas, sólo 12 correspondieron con el área y especies de estudio y por lo tanto fueron procesadas para crear una sola tabla de datos a partir de la información disponible en las carpetas.

El archivo BD_Subpesca_PINV_2012_2023_original.xlsx contiene los datos de las observaciones de peces dentro del área de interés en su estado original desde la base de datos adquirida.

Sin embargo, esta tabla fue modificada para conformar con el formato DwC antes de ser leída aquí. Se hicieron los siguientes cambios:

1. Primero, se combinaron varios campos para crear el campo `bibliographicCitation` (EJECUTOR, AÑO, N° DE RESOLUCIÓN SUBPESCA, TITULO PROYECTO, N° DE RESOLUCIÓN SUBPESCA, MANDANTE).
2. Luego, se renombraron las siguientes columnas como sigue:

```
AÑO -> year
MES -> month
HORA DE MUESTREO -> eventTime
ESTACIÓN -> locationRemarks
LATITUD -> verbatimLatitude
LONGITUD -> verbatimLongitude
NOMBRE CIENTÍFICO -> scientificName
NOMBRE COMÚN -> vernacularName
N° INDIVIDUOS -> individualCount
TIPO DE ARTE -> samplingProtocol
VALOR CPUE -> sampleSizeValue
UNIDAD CPUE -> sampleSizeUnit
N° DE INDIVIDUOS -> individualCount
```

3. Se estandarizaron las coordenadas geográficas transformado, según corresponda, a grados decimales mediante la herramienta *Convert Coordinate Notation (Data Management)* en ArcGIS. Las coordenadas estandarizadas se guardaron en dos nuevas variables `decimalLatitude` y `decimalLongitude`.

- Se añadieron nuevas variables con información encontrada en las carpetas, incluyendo:
`verbatimEventDate`
`eventDate`
`locality`
`samplingEffort`
`continent`
`country`
`countryCode`
`stateProvince`
`county`
`municipality`
- Un número de campos fueron omitidos (FUENTE, N° SACRIFICADOS, DIDYMO VISUAL, MUESTRA, PESO_MIN_GR, PESO_MAX_GR, PESO_PROMEDIO, PESO D.S., LONG_MIN_CM, LONG_MAX_CM, LONG_PROMEDIO, LONG_D.S., y otros).

En adelante se trabajó con la tabla de datos homologada que se lee a continuación.

6.6.1 Lectura de datos homologados

Se importó la tabla de datos preparada como se describe arriba.

```
SUBPESCA2 <- readxl::read_xlsx("./data_sources/SUBPESCA/SubpescaDB2/BD_Subpesca_PINV_2012_2023_homologada.xlsx",
  col_types = "text", col_names = T, na = "NA")

SUBPESCA2 <- SUBPESCA2 %>%
  mutate(decimalLongitude = as.numeric(decimalLongitude), decimalLatitude = as.numeric(decimalLatitude),
    individualCount = as.numeric(individualCount), day = as.numeric(day),
    month = as.numeric(month), year = as.numeric(year), eventDate = as.Date(eventDate))
```

El conjunto de datos presentó 12 referencias correspondientes a informes de resultados de pescas de investigación autorizadas por SUBPESCA en el marco del Sistema de Evaluación Ambiental (Tabla 6).

Table 6: Lista de referencias en el segundo conjunto de datos de SUBPESCA.

id	before
1	Maring Eirl (2012) Informe de resultados de pesca de investigación asociado al permiso SUBPESCA, R.EX N°262/2012. Proyecto: Evaluación limnológica-íctica, estero El Arco, Coyhaique, Región de Aysén. Mandante: Garo S.A.
2	Gaman Limno Studies Ltda. (2014) Informe de resultados de pesca de investigación asociado al permiso SUBPESCA, R.EX N°767/2014. Proyecto: Estudio Línea base de tipo limnológico del proyecto hidroeléctrico Chaica en el río Lenca, comuna de Puerto Montt, X Región. Mandante: Ingenium Civil S.A
3	Claudia Verdugo Castro (Ecosistema) (2016) Informe de resultados de pesca de investigación asociado al permiso SUBPESCA, R.EX N°3232/2016. Proyecto: Piscicultura de recirculación lago Balmaceda, Sealand Aquaculture S.A.; respuesta observación 1.2.8 ICSARA n°1 (064/2016). Mandante: Sealand Aquaculture S.A.
4	Icnova Ing Consultores (2018) Informe de resultados de pesca de investigación asociado al permiso SUBPESCA, R. EX N°388/2018. Proyecto: Diagnostico hidrobiológico de laguna Escondida y laguna Barrosa - declaración de impacto ambiental almacenamiento de agua de interior Mina Javiera en laguna Salitrosa, comuna de Chile Chico, XII Región de Aysén. Mandante: Compañía Minera Cerro Bayo Ltda.
5	Icnova Ing (2018) Informe de resultados de pesca de investigación asociado al permiso SUBPESCA, R. EX N°838/2018. Proyecto: Caracterización limnológica asociado al proyecto de riego Magallanes, embalse río Porvenir, XII region de Magallanes y la Antártica Chilena. Mandante: Comisión Nacional de Riego.
6	Martinez Ambiental Ltda (2019) Informe de resultados de pesca de investigación asociado al permiso SUBPESCA, R.EX N°1628/2019. Proyecto: Plan de vigilancia ambiental, asociado al proyecto Mina Invierno, comuna de Río Verde, región de Magallanes y Antártica Chilena. Mandante: Minera Invierno Sa.
7	Claudia Verdugo Castro (2020) Informe de resultados de pesca de investigación asociado al permiso SUBPESCA, R. EX N°65/2020. Proyecto: Monitoreo limnológico proyecto refundición de RCA's Amplición y cambio operacional, río Petrohué, comuna de Puerto Varas, región de Los Lagos. Mandante: Salmones Camanchaca S.A.
8	Claudia Verdugo Castro (2020) Informe de resultados de pesca de investigación asociado al permiso SUBPESCA, R. EX. N° E-2020-607 . Proyecto: Línea base limnológica Río Trainel cercano a la Piscicultura Trainel, región de Los Lagos. Mandante: Piscicultura Trainel.
9	Jaime Illanes y Asociados Consultores S.A. (2021) Informe de resultados de pesca de investigación asociado al permiso SUBPESCA, R. EX N°E-2021-074. Proyecto: Caracterización ecosistemas acuáticos continentales asociados al proyecto modificación Piscicultura los Tilcos, Río Chico Región de Los Lagos. Mandante: Piscicultura los Tilcos.




Fig. 7 Distribución de ocurrencias de peces del segundo conjunto de datos de SUBPESCA.

- 10 Juan Cárcamo Barriá (2017) Informe de resultados de pesca de investigación asociado al permiso SUBPESCA, R. EX N°411-2017. Proyecto: Caracterización de fauna íctica asociada al proyecto, piscicultura San Joaquín, sector El Varal, comuna de Hualaihué, X región de Los Lagos. Mandante: Cultivos Marinos Lago Yelcho S.P.A.
- 11 Las Orcas Spa. (Photosintesis) (2021) Informe de resultados de pesca de investigación asociado al permiso SUBPESCA, R. EX N°E-2021-117. Proyecto: Caracterización limnológica y uso de hábitats ribereños en los lagos Meullín, Yulton y Río cuervos, región del General Carlos Ibáñez del Campo. Mandante: Fundación Kreen.
- 12 Brian Reid (2022) Informe de resultados de pesca de investigación asociado al permiso SUBPESCA, R. EX N°E-2022-499. Proyecto: Efecto de sedimentos suspendidos a la alimentación de los peces nativos e introducidos, en la cuenca del río Simpson, región de Aysén. Centro de Investigación de Ecosistemas de la Patagonia.

6.6.2 Área de estudio

Solo se procesaron e ingresaron al conjunto de datos pescas de investigación practicadas dentro del área de estudio, por lo que no se requirió más filtros espaciales.

Mapa con datos filtrados espacialmente (Figura 7).

Además se añadió un identificador del conjunto de datos.

```
SUBPESCA2 <- SUBPESCA2 %>%
  mutate(occurrenceID = paste0("SUBPESCA.PescaInvestigacion2012-2023.",
    row_number()), datasetName = "SUBPESCA (2023) Resultados de pesca de investigación de peces de",
    license = "CC NC-BY 4.0", accessRights = "Datos obtenidos por ley de transparencia.")
```

6.6.3 Respaldo

```
write.csv(SUBPESCA2, "../data_sources/SUBPESCA/SubpescaDB2/Output_SUBPESCA2_DwC.csv",
  fileEncoding = "UTF-8", row.names = F)

saveRDS(SUBPESCA2, "../data_sources/SUBPESCA/SubpescaDB2/Output_SUBPESCA2_DwC.rds")
```

6.7 Darwin Initiative Fish Atlas

Nombre corto del conjunto de datos: DarwinFreshwaterFish

Referencia: Garcia de Leaniz, C.; Gajardo, G.; Consuegra, S.; Young, K.A.; Sanzana, J.; Vanhaecke, D.; Orellana, G.; Cerda, A.M.; Stephenson, J.F.; Terreau, A.; Thailly, A.F.; Perry, B.; Howes, P.N.; MacDonald, J. (2020). The Darwin Freshwater Fish Database of Exotic and Native Species in Chile. ([Garcia de Leaniz et al., 2020](#))

Archivo: Darwin Web Fish Database_associatedReferences.csv

Base de datos del proyecto *Darwin Initiative* ([Garcia de Leaniz et al., 2012](#)) financiado por el Department for Environment Food and Rural Affairs (DEFRA), del Reino Unido y liderado por Carlos García de Leániz (UK) y Gonzalo Gajardo (Chile, ULA). El propósito de este proyecto fue construir, en colaboración con el gobierno, la industria y otros actores relevantes, la capacidad de evaluar, monitorear y reducir el impacto de la introducción accidental o deliberada de especies de peces exóticas en la biodiversidad acuática chilena. Este proyecto se realizó en dos etapas:

- 2006-2009. Reducing the Impact of Exotic Aquaculture on Chilean Aquatic Biodiversity. Grant #15020, DEFRA, UK.
- 2010-2012. Protecting galaxiids from salmonid invasions in Chile and the Falklands. Grant EIDPO041, DEFRA, UK.

Uno de los productos fue una base de datos georeferenciada con los resultados de las pescas de investigación realizadas en la región de Los Lagos, Aysén e Islas Malvinas/Falkland. Las pescas se realizaron en su mayoría con pesca eléctrica.

Los datos fueron obtenidos con permiso de los autores principales (Carlos García de Leaniz y Gonzalo Gajardo) aunque posteriormente fueron publicados ([Garcia de Leaniz et al., 2020](#)).

Antes de ser usados en este análisis, los datos fueron agregados por fecha, especie y sitio de muestreo (la base de datos original es a nivel individual). También se corrigieron algunos registros en base a los resultados de identificación de especies mediante barcoding (atención Delphine Vanhaecke), y se añadió una columna para `associatedReferences` que vincula ocurrencias con varias publicaciones científicas que hicieron uso de ellas.

6.7.1 Lectura de datos

```
DIFA <- read.csv("../data_sources/Darwin_Initiative_Fish_Atlas/Darwin Web Fish Database_associatedReferences.csv",
  header = T, sep = ",", fileEncoding = "UTF-8", skip = 1,
  stringsAsFactors = F)
```

Preparación de los datos

```
DIFA <- DIFA %>%
  mutate(date = as.Date(paste0(Year, "-", Month, "-", Day)))
```

Las especies documentadas en este conjunto de datos fueron:

```
sort(unique(DIFA$Species))
```

```
## [1] "Aplochiton taeniatus"      "Aplochiton zebra"
## [3] "Azzatz hybrid"            "Basilichthys australis"
## [5] "Brachygalaxias bullocki"  "Cheirodon australe"
## [7] "Eleginops maclovinus"    "Galaxias maculatus"
## [9] "Galaxias platei"         "Geotria australis"
## [11] "Oncorhynchus kisutch"     "Oncorhynchus mykiss"
## [13] "Oncorhynchus tshawytscha" "Oncorhynchus tshawytscha "
## [15] "Percichthys trucha"       "Percilia gillissi"
## [17] "Salmo salar"              "Salmo trutta"
## [19] "Sculpin sp"               "Trichomycterus areolatus"
## [21] "Unknown"
```




Fig. 8 Distribución de ocurrencias de peces de la Iniciativa Darwin. Los puntos rojos fueron excluidos por estar fuera del área de estudio indicada por el polígono.

6.7.2 Filtrado y otras correcciones

Se corrigió un typo

```
DIFA$Species <- gsub(pattern = "Eleginops maclovins", replacement = "Eleginops maclovinus",
  DIFA$Species)
```

Se removieron especies no identificadas y mal identificadas,

```
DIFA <- DIFA %>%
  filter(Species != "Sculpin sp") %>%
  filter(Species != "Unknown")
```

y los híbridos de *Aplochiton* se identificaron como género *Aplochiton*, sin precisar la especie (sección *Estandarización taxonómica* en Capítulo 7).

Selección de variables

```
DIFA <- DIFA %>%
  select(Watershed, Location, Station, Latitude, Longitude,
    date, Species, Collected.by, n.individuals, associatedReferences)
```

6.7.3 Filtrado área de estudio

Se aplicó un filtro espacial para extraer las ocurrencias dentro del área de estudio.

Mapa con datos filtrados espacialmente (Figura 8).

6.7.4 Homologación al DwC

Primero se combinaron dos campos para crear *locality* del DwC.

```
tmp <- DIFA.filtered[, c("Watershed", "Location")]
DIFA.filtered$locality <- apply(tmp, 1, function(x) {
  paste0(unique(x), collapse = ", ")
})

DIFA.filtered <- DIFA.filtered %>%
  select(-Watershed, -Location)
```

Muchos sitios de muestreo en Chiloé y unos pocos en otros lugares solo tienen nombres crípticos (códigos), tales como *Río U23*, sin información adicional. Todos los sitios con este formato fueron renombrados añadiendo la palabra Chiloé (ej., *Chiloé, Río U23*), excepto por cuatro localizados en Chiloé Continental que se renombraron con con toponimia encontrada en mapas.

```
# Rename sites in continental Chiloé
DIFA.filtered <- DIFA.filtered %>%
  mutate(locality = recode(locality, `Río U80A` = "Estero de Reloncaví, Río Del Este",
    `Río U76A` = "Seno de Reloncaví, Qhillaípe", `Río U78` = "Chiloé continental, Río Puelche",
    `Río U8` = "Chiloé continental, Río entre Chauchil y Leguiman"))

# Rename all remaining sites with codes beginning with 'Río
# U'
tmp <- grepl("^Río U", DIFA.filtered$locality)
DIFA.filtered$locality[tmp] <- paste("Chiloé", DIFA.filtered$locality[tmp],
  sep = ", ")
```

Luego se renombraron los campos restantes para conformar el DwC:

```
DIFA.filtered <- DIFA.filtered %>%
  mutate(locality = locality, locationRemarks = Station, decimalLatitude = Latitude,
    decimalLongitude = Longitude, eventDate = as.Date(as.character(date)),
    scientificName = Species, recordedBy = Collected.by,
    individualCount = n.individuals, associatedReferences = associatedReferences,
    .keep = "none")
```

Además se añadieron algunos atributos del DwC que son constantes para todo el conjunto de datos.

```
DIFA.filtered$license <- "CC BY-NC 4.0"
DIFA.filtered$rightsHolder <- "Carlos García de Leaniz y Gonzalo Gajardo"
DIFA.filtered$accessRights <- "not-for-profit use only"
DIFA.filtered$bibliographicCitation <- "Leaniz, C.G.D., Gajardo, G., Consuegra, S., Young, K.A., Sa
DIFA.filtered$datasetName <- "Garcia de Leaniz, C.; Gajardo, et al. (2020) The Darwin Freshwater Fi
DIFA.filtered$basisOfRecord <- "Occurrence"
```

6.7.5 Corrección de errores

Se identificaron un número de errores (de geolocalización, de nombres de localidades, etc.) y se corrigieron.

```
# Wrong coordinates since it is located in the sea. Most
# likely was located in Huyar Bajo -42.398331, -73.553923,
# (after checking neighbouring sampling locations and other
# inconclusive info in the paper).

locationRemarks.toFix <- "U57A"

fix <- DIFA.filtered %>%
  transmute(fix = locationRemarks %in% locationRemarks.toFix) %>%
  pull()

DIFA.filtered <- DIFA.filtered %>%
  mutate(decimalLongitude = ifelse(fix, -73.553923, decimalLongitude),
    decimalLatitude = ifelse(fix, -42.398331, decimalLatitude))

## Check tmp <- DIFA.filtered %>% filter(fix) %>%
```

```
# select(locality, decimalLatitude, decimalLongitude,
# scientificName, locationRemarks) # Clean rm(fix,
# occurrenceID.toFix)
```

6.7.6 Respaldo

```
write.csv(DIFA.filtered, "./data_sources/Darwin_Initiative_Fish_Atlas/Output_DarwinInitiativeFishAtlas_DwC",
  fileEncoding = "UTF-8", row.names = F)

saveRDS(DIFA.filtered, "./data_sources/Darwin_Initiative_Fish_Atlas/Output_DarwinInitiativeFishAtlas_DwC.rds")

knitr::knit_exit()
```

References

- Aguilar, M. (2023). *Recopilación bibliográfica de ocurrencia de peces en la Patagonia del proyecto Priorización de Cuencas para la Conservación en Patagonia. Coyhaique*. Coyhaique: Programa Austral Patagonia (ProAP) de The Pew Charitable Trusts.
- Aguilar, M., Astorga, A., Reid, B. (2022). *Informe final proyecto: Priorización de cuencas para la conservación en Patagonia* (Tech. Rep.). Coyhaique: Programa Austral Patagonia (ProAP) de The Pew Charitable Trusts.
- Correa, C., & Boisjoly, M. (2025). *Base de datos empírica de peces de Chile*. Valdivia.
- Correa, C., Dyer, B.S., Garcia de Leaniz, Meier, C., Samaniego, H. (2009). Rumbo a un sistema nacional de información geográfica de peces dulceacuícolas de Chile Octubre 2009, Coyhaique. *VI Congreso Sociedad Chilena de Limnología*. Coyhaique.
- Dudgeon, D., Arthington, A.H., Gessner, M.O., Kawabata, Z.-I., Knowler, D.J., Leveque, C., ... Sullivan, C.A. (2006). Freshwater biodiversity: Importance, threats, status and conservation challenges. *Biological Reviews (Cambridge)*, 81(2), 163–182, <https://doi.org/10.1017/S1464793105006950>
- Garcia de Leaniz, C., Gajardo, G., Consuegra, S., Fowler, D., Rendell, N., Giannico, G., ... Dunham, J.B. (2012). *Protecting galaxiids from salmonid invasions in Chile and the Falklands* (Tech. Rep. No. grant EIDPO041). United Kindom: Department for Environment Food and Rural Affairs.
- Garcia de Leaniz, C., Gajardo, G., Consuegra, S., Young, K.A., Sanzana, J., Vanhaecke, D., ... MacDonald, J. (2020). *The Darwin Freshwater Fish Database of Exotic and Native Species in Chile* [Database]. figshare. Retrieved 2026-04-17, from <https://doi.org/10.6084/M9.FIGSHARE.13077350>
- GBIF-Secretariat (2023). *GBIF Backbone Taxonomy. Checklist dataset* <https://doi.org/10.15468/39omei> accessed via GBIF.org on 2025-11-25.
- Habit, E., Contreras, LM., Dyer, B.S., Correa, C., Naretto, J., Contreras, V., ... Villagran (2023). *Fauna Íctica Nativa Continental de Chile*. Occurrence dataset <https://doi.org/10.15468/cxb957> accessed via GBIF.org on 2025-10-17: Ministerio del Medio Ambiente de Chile.
- Reid, B., Astorga, A., Madriz, I., Correa, C. (2021). Estado del conocimiento y conservación de los ecosistemas dulceacuícolas de la Patagonia occidental austral. Castilla, Juan Carlos, Armesto, J..J., & Martínez-Harms, M. J. (Eds.), *Conservación en la Patagonia chilena: evaluación del conocimiento, oportunidades y desafíos* (Primera edición ed., p. 43). Santiago: Ediciones Universidad Católica.
- Wieczorek, J., Bloom, D., Guralnick, R., Blum, S., Döring, M., Giovanni, R., ... Vieglais, D. (2012). Darwin Core: An evolving community-developed biodiversity data standard. *PloS one*, 7(1), e29715, Retrieved 2025-11-25, from <https://journals.plos.org/plosone/article?id=10.1371/journal.pone.0029715>