

Atlas ictiogeográfico de la Patagonia occidental: homologación y consolidación de bases de datos

Cristian Correa^{1*} and Maryse Boisjoly¹

¹Instituto de Conservación Biodiversidad y Territorio, Universidad Austral de Chile, Valdivia, Chile.

*Corresponding author(s). E-mail(s): cristiancorrea@gmail.com;

Abstract

Por encargo del Programa Austral Patagonia (ProAP) de The Pew Charitable Trusts, se presenta una recopilación de información detallada de ocurrencia de peces de agua dulce, estuarinos y diadromos en la Patagonia occidental (40.8-56.0°S). Aquí se documenta en detalle la recopilación, análisis, y combinación de 12 conjuntos de datos de ocurrencias, obtenidos empíricamente (a través de prospecciones ictiológicas), a partir de revisiones de literatura, y de distintas bases de datos. El resultado es una base de datos geográfica de ocurrencia de peces en formato compatible con el Darwin Core standard. Hemos llamado al set de datos resultante Atlas Ictiogeográfico de la Patagonia Occidental.

Keywords: peces de agua dulce / freshwater fish, datos de ocurrencia / occurrence data, biomonitoring / biomonitoring, GBIF, Darwin Core, Patagonia occidental / Western Patagonia, Ecology, Conservation biology

Tabla de Contenidos

1	Introduction	3
2	Estrategia metodológica	3
3	Estándar Darwin Core (DwC)	4
4	Listado taxonómico de peces	6
5	Área de estudio y polígonos	8
6	Conjuntos de datos analizados	8
6.1	Datos empíricos de los autores	8
6.1.1	Lectura de datos	9
6.1.2	Filtrado y agregación de datos	10
6.1.3	Filtrado área de estudio	11
6.1.4	Homologación al formato DwC	12
6.1.5	Respaldo	13
6.2	Revisión de literatura C. Correa	13
6.2.1	Lectura de datos	13
6.2.2	Filtrado área de estudio	14
6.2.3	Homologación al DwC	14
6.2.4	Corrección de errores	16
6.2.5	Respaldo	17

Nota: Esta versión preliminar contiene etiquetas indicando detalles que necesitan atención por parte de los autores. Las etiquetas se identifican con el texto [HERE].

1 Introduction

Los ecosistemas dulceacuícolas tienen un alto grado de amenaza a nivel mundial (Dudgeon et al., 2006). Patagonia occidental no es una excepción, a pesar de la gran cobertura de áreas protegidas. Desde las vulnerables cabeceras de los ríos, y tramos inferiores que están excluidos desde las áreas protegidas, hasta el gran desconocimiento del estado poblacional y distribución de muchas especies dulceacuícolas (Reid, Astorga, Madriz, & Correa, 2021).

En el contexto de un primer esfuerzo regional en avanzar en la planificación de la conservación dulceacuícola en la Patagonia occidental, se desarrolló el informe “Priorización de cuencas para la conservación en Patagonia” (Aguilar, Astorga, & Reid, 2022), donde se identificaron tres ejes de avance: (1) la consolidación de información de biodiversidad de tres grupos taxonómicos dulceacuícolas, (2) la identificación de **subrogantes** geoespaciales que destaquen valores de conservación dulceacuícola, y (3) el desarrollo de un prototipo metodológico para la priorización de múltiples valores de conservación dulceacuícola a la escala de sub-subcuenca.

Una de las principales limitantes en esta primera iteración fue la carencia de información sobre biodiversidad dulceacuícola, donde resalta fuertemente el poco conocimiento y la baja densidad de observaciones comparado con otros esfuerzos similares en otras áreas geográficas (Aguilar et al., 2022, p. 26).

Aunque la literatura científica es una fuente importante de información sobre biodiversidad, también hay mucha información de las especies dulceacuícolas en la literatura gris, entidades estatales, bases de dato publicas GBIF y iNaturalist, y, finalmente, en el conocimiento de las/los expertos/as taxónomos y naturalistas. Mucho conocimiento e información que queda en las bases de dato de estos especialistas, que aún no es transcrita a observaciones oficiales, lo cual se relaciona directamente al escaso financiamiento para el trabajo de especialistas. Por lo tanto, una de las recomendaciones principales en este informe y de Reid et al. (2021) fue mejorar la información de biodiversidad integrando al grupo de trabajo a los/as expertas, que con su conocimiento especializado en cada grupo taxonómico lograrían mejorar, consolidar y evaluar las observaciones existentes de biodiversidad. Este atlas ictiográfico es el resultado de este esfuerzo, y también un ejemplo a seguir para otros grupos dulceacuícolas.

El presente documento detalla la metodología en la revisión del material existente, la recopilación, análisis, y combinación de diversos conjuntos de datos de ocurrencias de peces dulceacuícolas y diádomos obtenidos empíricamente (a través de prospecciones ictiológicas), a partir de revisiones de literatura, y de distintas bases de datos. El resultado es una base de datos geográfica de ocurrencia de peces en formato compatible con el Darwin Core standard (DwC), un estándar ampliamente adoptado para la distribución y consolidación de bases de datos biológicas de ocurrencia de especies por entidades tales como el Global Biodiversity Information Facility (GBIF) o la Superintendencia del Medio Ambiente, Gobierno de Chile.

2 Estrategia metodológica

La estrategia metodológica usada para combinar los conjuntos de datos se puede describir a grandes rasgos en cinco partes:

1. Cada set de datos fue visualizado en un mapa y revisado para identificar y corregir inconsistencias y errores.
2. Se homologaron los campos o atributos disponibles (columnas) en cada conjunto de datos con aquellos disponibles en el DwC (ver planilla *Atlas.Ictiogeografico.Homologacion.xlsx*). Básicamente, los nombres de las columnas de cada conjunto de datos fueron reemplazados por los nombres de los mismos atributos del DwC, y en algunos casos se combinaron los campos originales para producir uno homologado.
3. A cada conjunto de datos se le añadieron atributos (columnas) del DwC que son aplicables y propios a cada uno en su totalidad, tal como nombre del conjunto de datos (`datasetName`).
4. Los conjuntos de datos se combinaron en una gran base de datos geográfica reteniendo el mayor número posible de atributos homologados. Esta fue llamada **Atlas Ictiográfico de la Patagonia Occidental** y es el principal producto de este análisis.
5. Dado que hubo considerable redundancia entre conjuntos de datos, el atlas ictiogeográfico fue examinado de diferentes formas para identificar ocurrencias duplicadas (e.g., mismo registro reportado en dos o más conjuntos de datos). Para esto, se usaron tanto pruebas programáticas tal como la identificación de fechas

y coordenadas repetidas dentro de un rango acotado, como inspección manual de la tabla de atributos a una escala geográfica fina (e.g., sub-cuenca).

En los siguientes capítulos se documenta detalladamente (código R y prosa breve) la adopción del estándar DwC, el proceso de homologación (y otras manipulaciones) de cada conjunto de datos, y el refinamiento y consolidación del atlas ictiogeográfico. Al final, se presenta una breve sección de resultados preliminares examinando el contenido general del Atlas.

Se trabajó en

```
R.version
##
## platform      x86_64-w64-mingw32
## arch          x86_64
## os            mingw32
## crt           ucrt
## system        x86_64, mingw32
## status
## major         4
## minor         4.1
## year          2024
## month         06
## day           14
## svn rev       86737
## language      R
## version.string R version 4.4.1 (2024-06-14 ucrt)
## nickname      Race for Your Life
```

Al final de este documento se presenta la información completa de la sesión de trabajo en R.

3 Estándar Darwin Core (DwC)

“El *Darwin Core* (DwC) (Wieczorek et al., 2012) es un estándar mantenido por el Grupo de Interés de Mantenimiento de Darwin Core (Darwin Core Maintenance Interest Group). Incluye un glosario de términos (en otros contextos podrían llamarse propiedades, elementos, campos, columnas, atributos o conceptos) destinados a facilitar el intercambio de información sobre la diversidad biológica al proporcionar identificadores, etiquetas y definiciones. DwC se basa principalmente en taxa, su presencia en la naturaleza documentada por observaciones, especímenes, muestras e información relacionada.” (traducido de <https://github.com/tdwg/dwc>).

La adopción de un estándar es importante porque fomenta la interoperabilidad entre distintas plataformas y herramientas para el estudio y gestión de la biodiversidad a nivel internacional. El DwC es posiblemente el estándar vigente más ampliamente aceptado internacionalmente para datos de ocurrencia de especies.

La distribución del estándar se hace a través del portal GitHub del Darwin Core Maintenance Interest Group <https://github.com/tdwg/dwc>. Allí se encuentran definiciones, etiquetas, ejemplos, versiones anteriores, entre otros recursos, que a su vez son reflejados en una guía más fácil de leer (Darwin Core Quick Reference Guide).

Una lista de 179 atributos o campos (vigentes y obsoletos) con sus respectivas definiciones, etc., fue obtenida de GitHub (versión 2023-04-28), y de estos una fracción (~36) de los atributos vigentes fue considerado con algún grado de prioridad para los efectos de este proyecto, incluyendo aquellos destacados por la red GBIF como campos primarios y campos obligatorios. La lista completa de atributos y la priorización de esta está disponible en un archivo suplementario (input_parameters/Atlas_Ictiogeografico_Homologacion.xlsx). A continuación se reproduce parte de la lista de atributos seleccionados (Table 1).

Es importante destacar que el campo `eventDate` en el DwC tolera diferentes formatos tales como 2025-11-29 (año), 2025-11 (mes), 2025 (año), e incluso intervalos de tiempo 2023-09-05/2023-09-18 <https://techdocs.gbif.org/en/data-processing/temporal-interpretation>.

```
DwC <- readxl::read_xlsx("input_parameters/Atlas_Ictiogeografico_Homologacion.xlsx",
  sheet = "Matriz de homologacion", skip = 9)
```

Selección de campos que se consideraron prioritarios para este proyecto

```
DwC.keep <- DwC %>%
  filter(!is.na(`Prioridad campo` (MB.CC)))

# table(DwC.keep$`Prioridad campo` (MB.CC))
```

Table 1: Atributos seleccionados del estándar Darwin Core y su definición. Más detalles y ejemplos de cada uno en archivo excel suplementario.

Darwin Core Terms (DwC)	definition (DwC)
license	A legal document giving official permission to do something with the resource.
rightsHolder	A person or organization owning or managing rights over the resource.
accessRights	Information about who can access the resource or an indication of its security status.
bibliographicCitation	A bibliographic reference for the resource as a statement indicating how this record should be cited (attributed) when used.
references	A related resource that is referenced, cited, or otherwise pointed to by the described resource.
institutionID	An identifier for the institution having custody of the object(s) or information referred to in the record.
collectionID	An identifier for the collection or dataset from which the record was derived.
institutionCode	The name (or acronym) in use by the institution having custody of the object(s) or information referred to in the record.
collectionCode	The name, acronym, coden, or initialism identifying the collection or data set from which the record was derived.
datasetName	The name identifying the data set from which the record was derived.
basisOfRecord	The specific nature of the data record.
occurrenceID	An identifier for the Occurrence (as opposed to a particular digital record of the occurrence). In the absence of a persistent global unique identifier, construct one from a combination of identifiers in the record that will most closely make the occurrenceID globally unique.
catalogNumber	An identifier (preferably unique) for the record within the data set or collection.
recordNumber	An identifier given to the Occurrence at the time it was recorded. Often serves as a link between field notes and an Occurrence record, such as a specimen collector's number.
recordedBy	A list (concatenated and separated) of names of people, groups, or organizations responsible for recording the original Occurrence. The primary collector or observer, especially one who applies a personal identifier (recordNumber), should be listed first.
individualCount	The number of individuals present at the time of the Occurrence.
organismQuantity	A number or enumeration value for the quantity of organisms.
organismQuantityType	The type of quantification system used for the quantity of organisms.
lifeStage	The age class or life stage of the Organism(s) at the time the Occurrence was recorded.
associatedReferences	A list (concatenated and separated) of identifiers (publication, bibliographic reference, global unique identifier, URI) of literature associated with the Occurrence.

otherCatalogNumbers	A list (concatenated and separated) of previous or alternate fully qualified catalog numbers or other human-used identifiers for the same Occurrence, whether in the current or any other data set or collection.
eventDate	The date-time or interval during which an Event occurred. For occurrences, this is the date-time when the event was recorded. Not suitable for a time in a geological context.
year	The four-digit year in which the Event occurred, according to the Common Era Calendar.
verbatimEventDate	The verbatim original representation of the date and time information for an Event.
samplingProtocol	The names of, references to, or descriptions of the methods or protocols used during an Event.
samplingEffort	The amount of effort expended during an Event.
waterBody	The name of the water body in which the Location occurs.
locality	The specific description of the place.
decimalLatitude	The geographic latitude (in decimal degrees, using the spatial reference system given in geodeticDatum) of the geographic center of a Location. Positive values are north of the Equator, negative values are south of it. Legal values lie between -90 and 90, inclusive.
decimalLongitude	The geographic longitude (in decimal degrees, using the spatial reference system given in geodeticDatum) of the geographic center of a Location. Positive values are east of the Greenwich Meridian, negative values are west of it. Legal values lie between -180 and 180, inclusive.
coordinateUncertaintyInMeters	The horizontal distance (in meters) from the given decimalLatitude and decimalLongitude describing the smallest circle containing the whole of the Location. Leave the value empty if the uncertainty is unknown, cannot be estimated, or is not applicable (because there are no coordinates). Zero is not a valid value for this term.
typeStatus	A list (concatenated and separated) of nomenclatural types (type status, typified scientific name, publication) applied to the subject.
scientificName	The full scientific name, with authorship and date information if known. When forming part of an Identification, this should be the name in lowest level taxonomic rank that can be determined. This term should not contain identification qualifications, which should instead be supplied in the IdentificationQualifier term.
kingdom	The full scientific name of the kingdom in which the taxon is classified.
family	The full scientific name of the family in which the taxon is classified.
genus	The full scientific name of the genus in which the taxon is classified.

En el capítulo *Conjuntos de datos analizados* se presenta, uno a la vez, cada conjunto de datos con una breve descripción y la forma en que fue homologado para conformar el estándar DwC.

4 Listado taxonómico de peces

Algunas bases de datos globales requirieron ser filtradas para obtener ocurrencias de peces de interés para este proyecto, y este proceso se hizo basado en criterios geográficos y taxonomicos. Para el criterio taxonómico, este se dividió en dos etapas, una *a priori* y otra *a posteriori*.

En ambos casos se adoptó la clasificación taxonómica de *GBIF Backbone Taxonomy* ([GBIF-Secretariat \(2023\)](#)).

- Filtrado taxonómico *a priori*: Dentro de lo posible, se retuvieron todas las especies de peces (incluso marinas) hasta consolidar la base de datos homologada, y solo entonces se filtró para retener el conjunto de especies de nuestro interés (i.e., Filtrado taxonómico *a posteriori*). Para obtener datos de peces de algunos motores de búsqueda masiva (e.g., GBIF), se hizo una lista completa (inclusiva) de ordenes de

peces, para usarla como criterio de búsqueda. Este paso fue necesario porque la clase Actinopterygii ya no se considera un grupo taxonómico válido en el *GBIF Backbone Taxonomy* porque no es monofilético, lo que significa que no incluye a todos los descendientes de un solo ancestro común (Table 2).

```
res <- name_lookup(rank = "order", higherTaxonKey = 44, isExtinct = F,
  limit = 200)

# res$meta$count # Number of records available
# gbif_names(res) # online result viewer

# Filter fish orders (other taxa display classes in
# 'parent')
fish.orders <- res$data %>%
  filter(parent == "Chordata")
```

Table 2: Ordenes de peces incluidos en la lista de búsqueda a priori.

order	orderKey	taxonomicStatus	habitats
Acipenseriformes	1103	ACCEPTED	FRESHWATER, MARINE
Albuliformes	1104	ACCEPTED	FRESHWATER, MARINE
Amiiformes	494	ACCEPTED	FRESHWATER, MARINE
Anguilliformes	495	ACCEPTED	FRESHWATER, MARINE
Ateleopodiformes	1105	ACCEPTED	MARINE
Atheriniformes	496	ACCEPTED	FRESHWATER, MARINE
Aulopiformes	497	ACCEPTED	MARINE
Batrachoidiformes	1106	ACCEPTED	FRESHWATER, MARINE
Beloniformes	498	ACCEPTED	FRESHWATER, MARINE
Beryciformes	499	ACCEPTED	MARINE
Cetomimiformes	1107	ACCEPTED	MARINE
Characiformes	537	ACCEPTED	FRESHWATER, MARINE
Clupeiformes	538	ACCEPTED	FRESHWATER, MARINE
Cypriniformes	1153	ACCEPTED	FRESHWATER, MARINE
Cyprinodontiformes	547	ACCEPTED	FRESHWATER, MARINE
Elopiformes	1162	ACCEPTED	FRESHWATER, MARINE
Esociformes	548	ACCEPTED	FRESHWATER
Gadiformes	549	ACCEPTED	FRESHWATER, MARINE
Gasterosteiformes	550	ACCEPTED	FRESHWATER, MARINE
Gobiesociformes	1163	ACCEPTED	FRESHWATER, MARINE
Gymnotiformes	1165	ACCEPTED	FRESHWATER
Lampriformes	1166	ACCEPTED	MARINE
Lepisosteiformes	1167	ACCEPTED	FRESHWATER, MARINE
Lophiiformes	1305	ACCEPTED	MARINE
Mugiliformes	1067	ACCEPTED	FRESHWATER, MARINE
Myctophiformes	1306	ACCEPTED	MARINE
Notacanthiformes	1307	ACCEPTED	MARINE
Ophidiiformes	1308	ACCEPTED	FRESHWATER, MARINE
Osmeriformes	1068	ACCEPTED	FRESHWATER, MARINE
Osteoglossiformes	1069	ACCEPTED	FRESHWATER, MARINE
Perciformes	587	ACCEPTED	FRESHWATER, MARINE
Percopsiformes	1310	ACCEPTED	FRESHWATER
Pleuronectiformes	588	ACCEPTED	FRESHWATER, MARINE
Polymixiiformes	589	ACCEPTED	MARINE
Polypteriformes	1311	ACCEPTED	FRESHWATER
Saccopharyngiformes	1312	ACCEPTED	MARINE
Salmoniformes	1313	ACCEPTED	FRESHWATER, MARINE
Scorpaeniformes	590	ACCEPTED	FRESHWATER, MARINE
Siluriformes	708	ACCEPTED	FRESHWATER, MARINE
Stephanoberyciformes	890	ACCEPTED	MARINE
Stomiiformes	774	ACCEPTED	MARINE
Synbranchiformes	889	ACCEPTED	FRESHWATER, MARINE
Syngnathiformes	773	ACCEPTED	FRESHWATER, MARINE
Tetraodontiformes	772	ACCEPTED	FRESHWATER, MARINE
Zeiformes	888	ACCEPTED	FRESHWATER, MARINE

- Filtrado taxonómico *a posteriori*: Una vez homologada y consolidada la base de datos se revisó la lista de taxa resultante y se filtró para retener los taxa de peces de interés para este trabajo. Para esto se preparó una tabla completa de taxa encontrados y se las etiquetó como dulceacuícolas, estuarianas, o diádromas (código 1), y marinas (código 0). Las especies marinas fueron excluidas (ver sección *Consolidación del Atlas Ictiológico, Filtrado taxonómico*).

5 Área de estudio y polígonos

Se definió el área de estudio como el área comprendida por todas las cuencas con vertiente Pacífica que desembocan al sur de la cuenca del Río Maullín. Esto incluye desde Puerto Montt hacia el sur, incluyendo territorio Argentino de cuencas pacíficas, y mares interiores.

Se trabajó con un polígono originalmente proporcionado por Mary Aguilar, y posteriormente simplificado y generalizado a mano para incluir territorio marítimo donde habitan especies diádromas. Además, para mejorar la cobertura del área de estudio en la Patagonia chilena, se agregaron las cuencas chilenas que desembocan hacia el Atlántico. Estas cuencas se encuentran todas en la región de Magallanes. Este polígono fue simplificado nuevamente en QGIS (función *simplify*, with tolerance set to 0.000575) para reducir su número puntos a 9950, y poder ser usado en el motor de búsqueda de GBIF cuyo máximo es 10000 puntos (Study Area Polygon Pacific and Binational.Simp.shp).

```
shapefile_AE_Simp <- st_read("input_parameters/study_area/Study Area Polygon Pacific and Binational.Simp.shp",
  quiet = TRUE)

# Revert the order or orientation of the polygon, and
# convert to WKT for gbif queries.
study.area.wkt_Simp <- st_as_text(st_geometry(st_reverse(shapefile_AE_Simp)))

# Convert to data frame for plotting with ggmap
study.area <- fortify(shapefile_AE_Simp) #%>% filter(hole==FALSE)

# Extract coordinates from study.area and keep lat and long
# columns.
study.area_coords <- as.data.frame(st_coordinates(study.area)[,
  1:2])
colnames(study.area_coords) <- c("lon", "lat")

poly <- Polygons(list(Polygon(study.area_coords)), "poly")
sp_poly <- SpatialPolygons(Spl = list(poly), proj4string = CRS("EPSG:4326"))

study.area_simp <- fortify(shapefile_AE_Simp) #%>% filter(hole==FALSE)
```

El área de estudio resultante se aprecia en la Figura 1.

6 Conjuntos de datos analizados

Se incluyeron 12 conjuntos de datos en el análisis para generar el *Atlas Ictiogeográfico de la Patagonia*. Cada uno fue examinado, corregido en casos de errores, complementado con variables aplicables al nivel del conjunto de datos, y re-formateado para conformar al estándar DwC. Las siguientes secciones documentan el manejo que recibió cada conjunto de datos. Luego, en el capítulo *Consolidación del Atlas Ictiogeográfico*, se combinan todos los conjuntos de datos para conformar una gran tabla maestra que entre otras mejoras, se procesó para identificar ocurrencias duplicadas.

Durante la preparación de este documento algunos de los conjuntos de datos que habían sido incorporados fueron ingresados por las agencias de origen al Global Biodiversity Information Facility (GBIF). Por ejemplo, este es el caso de *Base de datos del MMA*. Aquí preservamos los capítulos originales que describen estos conjuntos de datos para entender mejor su origen y trazabilidad, pero ahora los datos se importan directamente desde GBIF. [HERE, check if we actually did this at the end.]

6.1 Datos empíricos de los autores

Nombre del conjunto de datos: Fish Database Correa-Boisjoly

Referencia: Correa, Cristián, Maryse Boisjoly (2025) Base de datos empírica de peces de Chile. Valdivia, Chile. (Correa & Boisjoly, 2025)

Archivo: FishDatabaseCorreaBoisjoly_2025-11-27.csv




Fig. 1 Área de estudio.

Este conjunto de datos corresponde a nuestros propios datos empíricos de registros de ocurrencias de peces dulceacuícolas, estuarinos y diádromos en la Patagonia. Algunos de estos registros ya han sido publicados antes pero hay muchos inéditos. Las ocurrencias han sido documentadas en el marco de un número de proyectos de investigación y sus respectivos permisos de pesca de investigación durante los últimos veinte años. En general, el foco de los muestreos ha sido documentar biodiversidad de peces nativos e introducidos, abarcando un amplio rango de técnicas de muestreo, hábitats y tallas, pero también se hicieron muestreos específicos.

Nuestros datos empíricos se encuentran almacenados en una base de datos relacional en formato MSAccess. A partir de esta, creamos una consulta (Query) incluyendo todas las ocurrencias de peces y un conjunto de atributos o campos relevantes que, como se describe a continuación, fueron homologados al estándar DwC.

6.1.1 Lectura de datos

A partir de la base de datos se exportó una tabla simple (FishDatabase_Correa_Boisjoly_2025-11-27.csv) que se importa y analiza a continuación:

```
FishDB_CC <- read.csv("./data_sources/Correa_Boisjoly_Collection/FishDatabase_Correa_Boisjoly_2025-11-27.csv")
# Site name
# Locality
# Site..waypoint.2014.
# Lat_effort
# Lon_effort
# SiteGear_FieldID
# Year
# Date
# Fishing_effort_Id
# Technique
# Fish_Id
# Given.ID
# YYYY.MM.DD
# Species
# N.Individuals
```

```

    "character", #Preserved."
    "character", #Crew"
    "character", #bibliographicCitation"
    "character"  #associatedReferences"
  ) )

```

```
FishDB_CC$"YYYY.MM.DD" <- as.Date(FishDB_CC$"YYYY.MM.DD", format = "%Y-%m-%d")
```

6.1.2 Filtrado y agregación de datos

En primer lugar, se filtró para retener solamente los peces de este conjunto de datos.

```

FishDB_CC <- FishDB_CC %>%
  filter(!(Species %in% invertebrates), !is.na(Species))
# where invertebrates is a vector of names to exclude, mostly
# invertebrates.

```

La tabla de peces resultante presentó 11449 filas o registros y 19 columnas o atributos. Las filas representan ocurrencias de individuos o conjuntos de individuos, por lo que para los efectos de este proyecto es pertinente agregar los datos (combinar filas) para obtener presencia de especies en sitios, fechas y protocolos de muestreos distintos.

Antes de agregar o combinar filas, se corrigieron algunas anomalías con el conteo de individuos para obtener el número de individuos registrado. En particular, cuando el campo N.Individuals estaba vacío se asumió $n = 1$ porque ese campo sirve sobre todo para acomodar conjuntos de peces indicando su número.

```

# Assume is.na(N.individuals) correspond to n = 1.
FishDB_CC$N.Individuals[is.na(FishDB_CC$N.Individuals)] <- 1

# Lots of still uncounted fish (e.g., photos of fish in
# trays) were originally flagged as N.Individuals = 999,
# and here that value was replaced by NA (all from Valdivia
# though).
FishDB_CC <- FishDB_CC %>%
  mutate(N.Individuals = ifelse((match(N.Individuals, 999,
    nomatch = 0) == 1), NA, N.Individuals))

```

Función para agregar los datos:

```

FishDB_CC_aggregated <- FishDB_CC %>%
  group_by(Locality, Lat_effort, Lon_effort, Year, YYYY.MM.DD,
    Species) %>%
  summarise(Fish_Id = paste0("Correa.Boisjoly.collection.",
    first(Fish_Id)), n = sum(N.Individuals), Technique = paste(unique(Technique),
    collapse = ", "), Site.name = paste(unique(Site.name),
    collapse = ", "), Crew = paste(unique(Crew), collapse = ", "),
    bibliographicCitation = {
      vals <- as.character(bibliographicCitation)
      vals <- trimws(vals)
      vals <- vals[!is.na(vals)]
      vals <- vals[!(vals %in% c("", "NA", "<NA>", "na"))]
      if (length(vals) == 0)
        "" else vals[1]
    }, associatedReferences = {
      vals <- as.character(associatedReferences)
      vals <- vals[!is.na(vals)]
      vals <- trimws(vals)
      vals <- vals[!(vals %in% c("", "NA", "<NA>", "na"))]
      if (length(vals) == 0) {
        ""
      } else {
        parts <- unlist(strsplit(vals, "\\s*\\\\|\\\\s*|;\\\\s*"))
      }
    })

```




Fig. 2 Distribución de ocurrencias de peces dulceacuícolas y diádromos según los datos empíricos de los autores de este informe. Datos dentro del polígono del área de estudio en azul.

```
parts <- trimws(parts)
parts <- parts[!(parts %in% c("", "NA", "<NA>",
"na"))]
parts <- unique(parts)
if (length(parts) == 0)
  "" else paste(parts, collapse = " | ")
}, .groups = "drop_last") %>%
ungroup()
```

Hubo muchas ocasiones en las que varios esfuerzos de muestreo practicados en un mismo lugar y fecha se agruparon en una sola fila por especie detectada. En otras palabras, algunas filas representan una ocurrencia obtenida mediante varios protocolos de muestreo. Por tanto, para simplificar, en lo sucesivo hemos optado por omitir identificadores tales como *Effort_Id* y *Fish_Id*.

6.1.3 Filtrado área de estudio

Se aplicó un filtro espacial para extraer las ocurrencias dentro del área de estudio

La versión agregando ocurrencias por fecha, sitio, y especie se redujo de 11449 a 750 filas u ocurrencias (Figura 2).

Los peces reportados por este conjunto de datos dentro del área de estudio se presentan en la Tabla 3.

Table 3: Lista de taxa encontrados en registros empíricos de Fish Database Correa-Boisjoly dentro del área de estudio.

Taxón	Taxón (continuación)
Aplochiton marinus	Odontesthes brevianalis
Aplochiton sp.	Odontesthes hatcheri
Aplochiton taeniatus	Odontesthes regia

Aplochiton zebra	Odontesthes smitti
Brachygalaxias bulloki	Oncorhynchus kisutch
Champscephalus esox	Oncorhynchus masou
Cheirodon	Oncorhynchus mykiss
Cheirodon interruptus	Oncorhynchus tshawytscha
Cottoperca trigloides	Patagonotothen
Eleginops maclovinus	Patagonotothen sp
Galaxias maculatus	Percichthys trucha
Galaxias maculatus	Salmo salar
Galaxias platei	Salmo trutta
Galaxias sp.	Salvelinus fontinalis
Geotria australis	Sardinops sagax
Geotria macrostoma	Sebastes
Hatcheria macraei	

6.1.4 Homologación al formato DwC

Los campos más importantes fueron homologados como indica la siguiente Tabla 4.

```
FishDB_CC.Fields <- colnames(FishDB_CC.aggregated)

DwC.eq <- FishDB_CC.Fields %>%
  recode(Fish_Id = "occurrenceID", Site.name = "locationRemarks",
    Locality = "locality", Lat_effort = "decimalLatitude",
    Lon_effort = "decimalLongitude", Year = "year", YYYY.MM.DD = "eventDate",
    Species = "scientificName", n = "individualCount", Technique = "samplingProtocol",
    Crew = "recordedBy", bibliographicCitation = "bibliographicCitation",
    associatedReferences = "associatedReferences")

colnames(FishDB_CC.aggregated) <- DwC.eq
FishDB_CC.ready <- FishDB_CC.aggregated[withinAE, ]
```

Table 4: Correspondencia entre atributos para homologar con DwC.

Fish Database Correa-Boisjoly	DwC equivalent
Locality	locality
Lat_effort	decimalLatitude
Lon_effort	decimalLongitude
Year	year
YYYY.MM.DD	eventDate
Species	scientificName
Fish_Id	occurrenceID
n	individualCount
Technique	samplingProtocol
Site.name	locationRemarks
Crew	recordedBy
bibliographicCitation	bibliographicCitation
associatedReferences	associatedReferences

Además se añadieron algunos atributos del DwC que son constantes para todo el conjunto de datos.

```
FishDB_CC.ready$license <- "CC BY-NC 4.0"
FishDB_CC.ready$rightsHolder <- "Cristian Correa, orcid.org/0000-0002-8608-6858"
FishDB_CC.ready$accessRights <- "not-for-profit use only"
# Add bibliographic citation where there is none (published
# papers prevail when available).
FishDB_CC.ready$bibliographicCitation[is.na(FishDB_CC.ready$bibliographicCitation) |
  trimws(FishDB_CC.ready$bibliographicCitation) == ""] <- "Correa, Cristian, and Maryse Boisjoly. 2025-11-27"
FishDB_CC.ready$datasetName <- "Correa-Boisjoly fish collection Version 2025-11-27"
FishDB_CC.ready$basisOfRecord <- "Occurrence"
```

6.1.5 Respaldo

```
write.csv(FishDB_CC.ready, "./data_sources/Correa_Boisjoly_Collection/Output_FishDatabase_Correa-Boisjoly",
          fileEncoding = "UTF-8", row.names = F)

saveRDS(FishDB_CC.ready, "./data_sources/Correa_Boisjoly_Collection/Output_FishDatabase_Correa-Boisjoly")
```

6.2 Revisión de literatura C. Correa

Nombre del conjunto de datos: FishGIS_metaDatabase_CC

Referencia: Correa, Cristian, B. Dyer, G. Gajardo, C. Garcia De Leaniz, C. Meier, H. Samaniego (2009) Rumbo a un sistema nacional de información geográfica de peces dulceacuícolas de Chile. Poster presentado en VI Congreso Sociedad Chilena de Limnología. Octubre 2009, Coyhaique. (Correa, Dyer, Garcia de Leaniz, Meier, & Samaniego, 2009)

Archivos: occurrences.csv, references.csv, site_coords.WGS84.csv, site_names.csv

Entre el período 2003-2009, uno de los autores de este reporte (CC) recabó, cual ratón de biblioteca, toda la literatura a su alcance sobre peces dulceacuícolas de Chile. Las bibliotecas consultadas incluyeron las principales Bibliotecas nacionales en Santiago, y algunas en Canadá, además de numerosos recursos online, préstamos interbibliotecarios, etc. A partir de este cuerpo de literatura, se obtuvieron datos de ocurrencias georeferenciadas que se incluyeron en este trabajo.

Nota: Esta revisión no pretende ser exhaustiva, y se presenta como fuente adicional de información potencialmente omitida por otras fuentes.

6.2.1 Lectura de datos

La base de datos original se encuentra organizada en una base de datos relacional en MS Access (toda la información no geográfica) y en QGIS (geoposicionamiento). Para este trabajo, se exportaron las tablas relevantes en un formato simple (*.csv), las cuales son importadas y procesadas a continuación para la producción de una sola tabla de ocurrencias con toda la información.

Tabla de nombres de sitios

```
site_names <- read.csv("./data_sources/FishGIS_metaDatabase/CorreaFishOccurrenceReview/site_names.csv",
                      fileEncoding = "UTF-8", colClasses = "character", stringsAsFactors = FALSE)
# site_names %>% count(Site_ID) %>% filter(n > 1) # Good,
# unique

site_names <- site_names %>%
  select(Site_ID, Site_Name, Site_Precision, Notes, Years,
         Dates, Number_of_Dates, Samp_method, Number_of_fish,
         Fishing_gear, OLD_Primary_key, OLD_SITE_ID, OLD_ID, Review) %>%
  mutate(Site_ID = trimws(Site_ID))
```

Tabla de coordenadas geográficas (los puntos se digitalizaron previamente en un SIG)

```
# Site coordinates table.
site_coords_WGS84 <- read.csv("./data_sources/FishGIS_metaDatabase/CorreaFishOccurrenceReview/site_coords_WGS84.csv",
                              fileEncoding = "UTF-8", colClasses = "character", stringsAsFactors = FALSE)
site_coords_WGS84 <- site_coords_WGS84 %>%
  distinct() %>% # Make table unique
  relocate(Site_ID)
# site_coords_WGS84 %>% count(Site_ID) %>% filter(n > 1) # Good, unique

site_coords_WGS84 <- site_coords_WGS84 %>%
  mutate(decimalLongitude = round(as.numeric(decimalLongitude),5),
         decimalLatitude=round(as.numeric(decimalLatitude),5),
         Site_ID = trimws(Site_ID))
```

Tabla de ocurrencias

```
occurrences <- read.csv("./data_sources/FishGIS_metaDatabase/CorreaFishOccurrenceReview/occurrences.csv",
                        fileEncoding = "UTF-8", colClasses = "character", stringsAsFactors = FALSE)
```

```
# occurrences %>% count(Species_ID) %>% filter(n > 1) #
# Good, unique

occurrences <- occurrences %>%
  mutate(Species_ID = trimws(Species_ID), Site_ID = trimws(Site_ID),
         Ref_ID = trimws(Ref_ID))

# Se removieron filas que no aportaban registros de
# especies.
occurrences <- occurrences %>%
  filter(Species != "?")
```

Tabla de referencias bibliográficas

```
references <- read.csv("./data_sources/FishGIS_metaDatabase/CorreaFishOccurrenceReview/references.csv",
  fileEncoding = "UTF-8", colClasses = "character", stringsAsFactors = FALSE)
# references %>% count(Ref_ID) %>% filter(n > 1) # Good,
# unique

references$bibliographicCitation <- with(references, paste0(Author,
  " (", Year, ") ", Title, ". ", Journal.or.Editorial, " ",
  Vol..Pag, "."))

references <- references %>%
  select(Ref_ID, bibliographicCitation) %>%
  mutate(bibliographicCitation = bibliographicCitation %>%
    str_trim() %>%
    str_replace_all("(\\s*\\.\\.\\s*)+$", "") %>%
    ifelse(. == "" | is.na(.), ., str_c(., ".")), Ref_ID = trimws(Ref_ID))
```

Combinar tablas. A continuación se pobló la tabla de ocurrencias con información geográfica, datos de sitios de muestreo y referencias bibliográfica.

```
metaDB.CC <- occurrences %>%
  left_join(site_names, by = c(Site_ID = "Site_ID")) %>%
  left_join(site_coords.WGS84, by = c(Site_ID = "Site_ID")) %>%
  left_join(references, by = c(Ref_ID = "Ref_ID"))
```

La tabla de datos presentó 2020 filas u ocurrencias y 47 columnas o variables.

6.2.2 Filtrado área de estudio

Antes de filtrar el área de estudio se excluyeron 166 filas sin coordenadas geográficas. Si bien las coordenadas de muchas de estas filas se encuentran en el campo *Notas*, se comprobó que las 11 referencias afectadas ya fueron indexadas por otros conjuntos de datos.

```
metaDB.CC <- metaDB.CC %>%
  filter(!is.na(decimalLongitude))
```

Se extrajeron los datos dentro del área de estudio:

La Figura 3 muestra los datos filtrados espacialmente.

Luego de filtrar por el área de estudio, el conjunto de datos se redujo a 343 ocurrencias, registradas en 167 sitios, y obtenido de 30 referencias.

6.2.3 Homologación al DwC

Primero se acuñó la variable año del registro *year* basada en el primer año mencionado en *Years*, variable que ocasionalmente incluyó 2 o más años calendario.

```
# Enter approximate date for this reference including
# record from Lago Yulton and few others (Soto et al. 2006)
metaDB.CC.filtered$Years[metaDB.CC.filtered$Years == "Not specified (between 1990 and 2005)"] <- 1997
```




Fig. 3 Distribución de ocurrencias de peces de revisión de literatura (Correa et al. 2009). Los puntos rojos fueron excluidos por estar fuera del área de estudio indicada por el polígono.

```
# Extract first year
metaDB.CC.filtered$year <- as.numeric(gsub("(^\\d{4}).*", "\\1",
  metaDB.CC.filtered$Years))
```

Además se acuñó la variable `eventDate` que tolera varios formatos de fechas incluyendo intervalos de tiempo, según el DwC.

```
metaDB.CC.filtered <- metaDB.CC.filtered %>%
  mutate(eventDate = sapply(Years, function(x) {
    if (is.na(x) || str_trim(x) == "")
      return(NA_character_)

    yrs <- str_extract_all(x, "\\d{4}")[[1]]
    yrs <- sort(unique(as.integer(yrs)))

    if (length(yrs) == 0) {
      NA_character_
    } else if (length(yrs) == 1) {
      as.character(yrs[1])
    } else {
      paste0(min(yrs), "/", max(yrs) + 1)
    }
  }))
```

Luego se guardó información que no calza bien con el DwC en una nueva variable `eventRemarks`. Esta incluye una idea de la precisión de la geolocalización. (No se usaron variables tales como `coordinateUncertaintyInMeters` o `coordinatePrecision` porque el formato narrativo no concuerda con las definiciones del DwC.)

```
metaDB.CC.filtered$eventRemarks <- with(metaDB.CC.filtered, ifelse(Site_Precision !=
  "", paste(Years, Notes.x, "Geolocation:", Site_Precision),
  paste(Years, Notes.x)))
```

Se seleccionaron las columnas con información relevante y se homologaron con el DwC sustituyendo sus nombres.

```
metaDB.CC.filtered <- metaDB.CC.filtered %>%
  select(Species_ID, decimalLongitude, decimalLatitude, Site_Name,
         Species, year, eventDate, bibliographicCitation, eventRemarks)

colnames(metaDB.CC.filtered) <- recode(colnames(metaDB.CC.filtered),
  Species_ID = "occurrenceID", decimalLongitude = "decimalLongitude",
  decimalLatitude = "decimalLatitude", Site_Name = "locality",
  Species = "scientificName", year = "year", eventDate = "eventDate",
  bibliographicCitation = "bibliographicCitation", eventRemarks = "eventRemarks")
```

Se añadió un prefijo a occurrenceID para identificar el conjunto de datos.

```
metaDB.CC.filtered <- metaDB.CC.filtered %>%
  mutate(occurrenceID = paste0("CCCorrea.Lit.Review.", occurrenceID))
```

Además se añadieron algunos atributos del DwC que son constantes para todo el conjunto de datos.

```
metaDB.CC.filtered$license <- "CC BY-NC 4.0"
metaDB.CC.filtered$datasetName <- "Literature review dataset of Chilean freshwater and diadromous fish"
metaDB.CC.filtered$basisOfRecord <- "Occurrence"
```

6.2.4 Corrección de errores

Se identificaron un número de errores (de geolocalización, de nombres de localidades, etc.) y se corrigieron.

```
# Locality 'Laguna Ventisquero (estero Ventisquero)',
# change coordinates to -48.250000, -73.591667, moving
# point closer to the fiord in another basin.

fix <- metaDB.CC.filtered %>%
  transmute(fix = (decimalLatitude == -47.47356 & decimalLongitude ==
    -73.29885)) %>%
  pull()

metaDB.CC.filtered <- metaDB.CC.filtered %>%
  mutate(decimalLongitude = ifelse(fix, -73.59167, decimalLongitude),
    decimalLatitude = ifelse(fix, -48.25, decimalLatitude))

# Change Locality from Lago Risopatrón to Río Simpson,
# after reviewing the actual paper

fix <- metaDB.CC.filtered %>%
  transmute(fix = (decimalLatitude == -45.43213 & decimalLongitude ==
    -72.41295)) %>%
  pull()

metaDB.CC.filtered <- metaDB.CC.filtered %>%
  mutate(locality = ifelse(fix, "Río Simpson", locality))
rm(fix)

# Change coordinates to the site where the historical Río
# Pratt Hatchery was located.

fix <- metaDB.CC.filtered %>%
  transmute(fix = (decimalLatitude == -52.68588 & decimalLongitude ==
    -72.01994)) %>%
  pull()

metaDB.CC.filtered <- metaDB.CC.filtered %>%
  mutate(decimalLongitude = ifelse(fix, -72.73421, decimalLongitude),
    decimalLatitude = ifelse(fix, -51.56258, decimalLatitude))
```

```
rm(fix)
```

6.2.5 Respaldo

```
write.csv(metaDB.CC.filtered, "../data_sources/FishGIS_metaDatabase/Output_CCorreaLitReview.csv",  
          fileEncoding = "UTF-8", row.names = F)  
  
saveRDS(metaDB.CC.filtered, "../data_sources/FishGIS_metaDatabase/Output_CCorreaLitReview.rds")  
  
knitr::knit_exit()
```

References

- Aguilar, M., Astorga, A., Reid, B. (2022). *Informe final proyecto: Priorización de cuencas para la conservación en Patagonia* (Tech. Rep.). Coyhaique: Programa Austral Patagonia (ProAP) de The Pew Charitable Trusts.
- Correa, C., & Boisjoly, M. (2025). *Base de datos empírica de peces de Chile*. Valdivia.
- Correa, C., Dyer, B.S., Garcia de Leaniz, Meier, C., Samaniego, H. (2009). Rumbo a un sistema nacional de información geográfica de peces dulceacuícolas de Chile Octubre 2009, Coyhaique. *VI Congreso Sociedad Chilena de Limnología*. Coyhaique.
- Dudgeon, D., Arthington, A.H., Gessner, M.O., Kawabata, Z.-I., Knowler, D.J., Leveque, C., ... Sullivan, C.A. (2006). Freshwater biodiversity: Importance, threats, status and conservation challenges. *Biological Reviews (Cambridge)*, 81(2), 163–182, <https://doi.org/10.1017/S1464793105006950>
- GBIF-Secretariat (2023). *GBIF Backbone Taxonomy. Checklist dataset* <https://doi.org/10.15468/39omei> accessed via GBIF.org on 2025-11-25.
- Reid, B., Astorga, A., Madriz, I., Correa, C. (2021). Estado del conocimiento y conservación de los ecosistemas dulceacuícolas de la Patagonia occidental austral. Castilla, Juan Carlos, Armesto, J..J., & Martínez-Harms, M. J. (Eds.), *Conservación en la Patagonia chilena: evaluación del conocimiento, oportunidades y desafíos* (Primera edición ed., p. 43). Santiago: Ediciones Universidad Católica.
- Wieczorek, J., Bloom, D., Guralnick, R., Blum, S., Döring, M., Giovanni, R., ... Vieglaiss, D. (2012). Darwin Core: An evolving community-developed biodiversity data standard. *PloS one*, 7(1), e29715, Retrieved 2025-11-25, from <https://journals.plos.org/plosone/article?id=10.1371/journal.pone.0029715>